

UNIVERSIDADE FEDERAL DE UBERLÂNDIA

Luis Eduardo da Silva Ribeiro

**Predição de escalações para o jogo CartolaFC  
utilizando aprendizado de máquina e otimização**

**Uberlândia, Brasil**

**2019**

UNIVERSIDADE FEDERAL DE UBERLÂNDIA

Luis Eduardo da Silva Ribeiro

**Predição de escalações para o jogo CartolaFC utilizando  
aprendizado de máquina e otimização**

Trabalho de conclusão de curso apresentado  
à Faculdade de Computação da Universidade  
Federal de Uberlândia, Minas Gerais, como  
requisito exigido parcial à obtenção do grau  
de Bacharel em Ciência da Computação.

Orientador: Márcia Aparecida Fernandes

Universidade Federal de Uberlândia – UFU

Faculdade de Computação

Bacharelado em Ciência da Computação

Uberlândia, Brasil

2019

Luis Eduardo da Silva Ribeiro

## **Predição de escalações para o jogo CartolaFC utilizando aprendizado de máquina e otimização**

Trabalho de conclusão de curso apresentado à Faculdade de Computação da Universidade Federal de Uberlândia, Minas Gerais, como requisito exigido parcial à obtenção do grau de Bacharel em Ciência da Computação.

Uberlândia, Brasil, 10 de julho de 2019:

---

**Márcia Aparecida Fernandes**  
Orientador

---

**Rita Maria da Silva Julia**  
Examinadora

---

**Luiz Gustavo Almeida Martins**  
Examinador

Uberlândia, Brasil  
2019

# Resumo

O CartolaFC é um jogo no qual é possível realizar a escalação de times virtuais com base nos jogadores e técnicos da série A do campeonato brasileiro de futebol. Nesse sentido, o trabalho utiliza técnicas de aprendizado de máquina e otimização para predição de escalações no CartolaFC. Inicialmente, foi realizado o pré-processamento da base de dados obtida para o desenvolvimento do trabalho. Posteriormente, foi realizada uma análise estatística para identificação de classes de jogadores baseado em *boxplots*. Além disso, foi modelada uma rede neural *perceptron* para realizar a classificação dos jogadores baseada nas classes definidas na etapa anterior, utilizando para treinamento os dados de 2014 a 2018 e as rodadas 6 e 7 do ano de 2019 do campeonato brasileiro para testes. Finalmente foi construído um algoritmo genético responsável por escalar os times, levando em consideração restrições de patrimônio disponível para escalação e esquema tático. Os resultados do trabalho sugerem que o limite de patrimônio disponível para escalação influencia na qualidade dos times escalados e que a utilização de um algoritmo genético no processo de escalação consegue evoluir a qualidade dos times escalados à medida que as gerações se passam.

**Palavras-chave:** Cartola, redes neurais, algoritmos genéticos, escalação, jogadores.

# 1 Introdução

"Atualmente, em termos mundiais, o volume de dados armazenados é gigantesco e continua crescendo rapidamente. Infelizmente, devido à incapacidade do ser humano de interpretar tamanha quantidade de dados, muita informação e conhecimento, possivelmente úteis, podem estar sendo desperdiçados, ficando ocultos dentro das bases de dados espalhadas pelo mundo. Em consequência disso, a necessidade de se desenvolver novas ferramentas e técnicas de extração de conhecimento a partir de dados armazenados também vem crescendo e se mostrando cada vez mais indispensável".(REZENDE, 2003, p.397)

Nesse sentido, uma área de Inteligência Artificial que têm se destacado é o aprendizado de máquina. "Ela tem como objetivo o desenvolvimento de técnicas computacionais sobre o aprendizado bem como a construção de sistemas capazes de adquirir conhecimento de forma automática".(MONARD; BARANAUSKAS, 2003).

Nesse contexto, o aprendizado de máquina pode ser uma ferramenta útil no cenário de jogos, para entendimento das melhores estratégias, utilizando-se de informações armazenadas em bases de dados. No cenário de *fantasy games*, onde é possível realizar a montagem de times virtuais com jogadores reais participantes de modalidades esportivas, diversos trabalhos vêm sendo desenvolvidos na criação de modelos que consigam aumentar a performance nos resultados. Especialmente para o jogo CartolaFC <sup>1</sup>, já foram utilizadas técnicas como *Extreme Gradient Boosting*, *Random Forest* e *Support Vector Machine* (VISCONDI; GARCIA; JUSTO, 2017), além da utilização de árvores de regressão no processo de predição de escalações dos times (LIMA; PASQUINI; TRAVIZAN, 2018).

O CartolaFC é um *fantasy game* criado pelo Globoesporte <sup>2</sup>, no qual é possível escalar um time virtual com base nos atletas e treinadores que fazem parte dos times do Campeonato Brasileiro da Serie A de futebol. Ao longo de 38 rodadas, os cartoleiros, como são chamados os usuários do jogo, escalam seus times, buscando maximizar sua pontuação. A pontuação total do time é obtida por meio da soma de pontuações individuais dos jogadores e do técnico que foram escolhidos para compor a escalação. Dessa forma, o objetivo do jogo consiste em acumular a maior quantidade de pontos dentre todos os cartoleiros no final do campeonato para ser o campeão da disputa.

Entretanto, o processo de escalação a cada rodada envolve uma análise criteriosa do histórico de estatísticas relativas aos jogadores, como por exemplo, número de assistências, faltas cometidas e gols marcados, na tentativa de otimizar a pontuação do time escalado.

---

<sup>1</sup> <https://cartolafc.globo.com>

<sup>2</sup> <https://globoesporte.globo.com/>

Além da análise dos jogadores, os cartoleiros também analisam os jogos de cada rodada no processo de escolha dos atletas a serem escalados. Essa tarefa é realizada por meio da análise do histórico de desempenho das equipes como o número de vitórias e derrotas ao longo do campeonato, além da *performance* dos times jogando dentro e fora de casa. Por fim, os competidores não podem escalar livremente qualquer combinação de atletas que desejam. Existe uma limitação com relação ao patrimônio disponível para escalação dos jogadores, pois cada atleta possui um preço que aumenta ou diminui baseado em seu desempenho no decorrer das rodadas.

Dessa forma, este trabalho utilizará algoritmos de aprendizado de máquina e otimização para o CartolaFC, na construção de um modelo que será utilizado para predição das escalações a cada rodada, levando em consideração não apenas as estatísticas relativas aos jogadores, mas também o patrimônio disponível, e os esquemas táticos disponíveis para escalação dos atletas.

## 1.1 Justificativa

O mercado de *fantasy games* está presente em várias partes do mundo. No Brasil, temos como exemplo o próprio CartolaFC. Nos Estados Unidos, existem o *FanDuel*<sup>3</sup> e *DraftKings*<sup>4</sup> onde é possível escalar times de diversas modalidades esportivas, tais como o basquetebol e o futebol americano. Já na Inglaterra, temos o *Fantasy Premier League*<sup>5</sup> no qual é possível montar times fictícios com base nos atletas participantes da principal liga de futebol inglesa.

Além da questão de entretenimento para os competidores, existe também a visão de mercado envolvida em ambas as partes. No caso dos provedores da plataformas de *fantasy games*, geralmente existe a cobrança de uma taxa para que os competidores possam jogar. Dessa forma, quanto mais usuários pagam para utilização do jogo, maior é o lucro obtido. No CartolaFC, por exemplo, existem duas modalidades de competição, sendo a primeira grátis e a segunda paga. Na primeira não é paga nenhuma taxa, mas não é possível ganhar prêmios, e outra, denominada Cartola *Pro*, onde mediante o pagamento de um determinado valor, é possível ganhar prêmios ao término de cada rodada, além de uma série de benefícios.

Do ponto de vista dos competidores, existe o interesse financeiro nas premiações estipuladas no regulamento dos *fantasy games*. Segundo [Globo \(2019\)](#), na modalidade Cartola *Pro*, os melhores cartoleiros são premiados a cada rodada com vale-compras de até R\$5.000,00 e ao final do campeonato de até R\$10.000,00. Na edição do ano de 2019, será sorteado um carro 0km ao final do campeonato para quem for cartoleiro *Pro*.

---

<sup>3</sup> <https://www.fanduel.com/>

<sup>4</sup> <https://www.draftkings.com/>

<sup>5</sup> <https://fantasy.premierleague.com/>

Além da questão financeira, um outro elemento motivador para o desenvolvimento desse trabalho, foi a dificuldade envolvida no processo de tomada de decisão na escolha dos atletas que compõem os times a cada rodada. Além da análise do histórico de seus desempenhos, e da restrição de patrimônio disponível para composição do time, que são partes importantes para nortear o processo de seleção dessa combinação ótima, existe um grande espaço de busca de possíveis soluções.

Para exemplificar a complexidade envolvida nesse processo, após consulta à base dos dados que foram utilizados para o desenvolvimento desse trabalho, foi calculado o número de escalações possíveis considerando a quantidade de jogadores com o status de prováveis para a última rodada do campeonato brasileiro de 2018. Foram identificados nessa consulta um total de 19 goleiros, 38 zagueiros, 36 laterais, 72 meias, 42 atacantes e 20 técnicos. Considerando o esquema tático 4-4-2 que é composta por 4 jogadores de defesa sendo dois 2 zagueiros e 2 laterais, 4 meio-campistas e 2 atacantes, temos um total de  $2,862269913 \times 10^{19}$  possíveis escalações.

## 1.2 Objetivos

O objetivo deste trabalho propõe um modelo para predição de escalações de times no CartolaFC, levando em consideração questões como o esquema tático e a limitação de patrimônio disponível para escalar, utilizando técnicas de aprendizado de máquina e otimização. Após a construção desse modelo, foi avaliada a utilização do algoritmo genético construído no processo de escalação de times no CartolaFC, por meio da qualidade dos times produzidos. Também foi realizado um estudo sobre a utilização de diferentes limites de patrimônio na produção dos times.

Para que os objetivos supracitados fossem atingidos, foi necessário alcançar os seguintes objetivos específicos:

- Padronizar os dados obtidos do repositório caRtolá.
- Identificar classes de jogadores por meio da análise de dados.
- Modelar uma rede neural artificial *perceptron* para classificação dos atletas.
- Formular o processo de escalação de times no CartolaFC como um problema de optimização.
- Modelar e implementar o algoritmo genético responsável pela escalação dos times.

### 1.3 Metodologia

A primeira etapa consiste em realizar a coleta dos dados, para que seja possível a realização do trabalho. Dessa maneira, uma alternativa seria a captura dos dados diretamente da base de dados do CartolaFC, para obtenção das estatísticas dos jogadores. Entretanto, essas informações estão em estado bruto, necessitando de tratamento antes de serem utilizadas.

Felizmente, existe um repositório no *GitHub* chamado 'caRtol', no qual toda a parte de obtenção e tratamento dos dados do jogo já foi realizada. Dessa forma, os dados estão organizados por ano em arquivos de extensão 'csv' contendo as estatísticas dos atletas. Durante a etapa de pré-processamento, foram as calculadas médias das estatísticas dos atletas, ao invés de valores agregados, para padronização dos dados.

Posteriormente, foi realizada uma proposta de divisão dos atletas em classes utilizando a estrutura do *boxplot*, com base na média de pontuação dos jogadores. Encerrada a etapa de análise de dados, foi modelada uma rede neural artificial *perceptron* de múltiplas camadas para realizar o processo de classificação dos jogadores nas classes definidas na etapa anterior. No processo de modelagem da rede, foi utilizada como exemplo uma estrutura de uma rede neural que também realiza a tarefa de classificação em um problema semelhante dentro do contexto de aprendizado de máquina. Para treinamento dessa rede, foram utilizados os dados do CartolaFC de 2014 até 2018, e para testes foram usadas as rodadas 6 e 7 do campeonato brasileiro de 2019. Após realização de testes na rede neural, os atletas que obtiveram uma classificação ruim foram retirados da base de dados que foi levada para a próxima etapa de desenvolvimento do trabalho.

Além disso, foi realizada a modelagem formal do processo de escalação como um problema de otimização, definindo a função objetivo e restrições dentro do modelo. Finalmente, foi realizada a modelagem e implementação do algoritmo genético responsável pela escalação dos times, definindo a representação do indivíduo, função de avaliação, além das operações genéticas de seleção dos pais, *crossover*, mutação e seleção da nova população.

### 1.4 Organização do trabalho

No Capítulo 2, será apresentada toda a fundamentação teórica utilizada no desenvolvimento do trabalho. Na Seção 2.1, será realizada a definição dos conceitos relacionados às redes neurais e seu funcionamento. Na Seção 2.2, será mostrado o conceito de um problema de otimização e como realizar sua formulação. Na Seção 2.3, será realizada a definição dos conceitos relacionados aos algoritmos genéticos e seu funcionamento. Na Seção 2.4 será apresentado o conceito de *boxplot* e sua composição. Na Seção 2.5,

será apresentada a definição do jogo CartolaFC e suas regras de funcionamento. Já na Seção 2.6, serão apresentados os trabalhos correlatos utilizados como inspiração para o desenvolvimento do trabalho.

No Capítulo 3, será mostrado todo o desenvolvimento da pesquisa realizada. Na Seção 3.1, será mostrado o processo de aquisição e pré-processamento dos dados obtidos. Na Seção 3.2, será mostrada toda a análise estatística realizada por meio de *boxplots* para identificação das classes de jogadores. Na Seção 3.3, será exibida a definição da rede neural que irá realizar a classificação dos jogadores, além de mostrar os resultados obtidos no processo de classificação. Na Seção 3.4, será feita a modelagem do processo de escalação como um problema de otimização. Na Seção 3.5 é mostrado como o algoritmo genético implementa as operações para geração, cruzamento e mutação dos times.

No Capítulo 4, serão apresentados os resultados da pesquisa. Na Seção 4.1 serão apresentados os resultados obtidos para a rodada 6. Na Seção 4.2 serão apresentados os resultados obtidos para a rodada 7. Na Seção 4.3 será realizada a comparação da pontuação média obtida entre diferentes limites de patrimônio por rodada. Por fim, no Capítulo 5 serão apresentadas as conclusões do trabalho, as contribuições obtidas e os trabalhos futuros.

## 2 Fundamentação Teórica

Neste capítulo, serão apresentados os conceitos necessários para compreensão das técnicas de redes neurais e algoritmos genéticos, a definição e as regras do jogo CartolaFC, bem como os trabalhos relacionados.

### 2.1 Redes neurais artificiais

Nesta seção, serão apresentados os conceitos básicos para compreensão do funcionamento de uma rede neural artificial.

#### 2.1.1 Neurônio artificial

Um neurônio artificial é uma estrutura utilizada como base para o desenvolvimento de uma rede neural artificial e sua modelagem é inspirada no sistema neurológico humano. Assim, o neurônio recebe sinais de entrada, que são os dados a serem processados. Esses sinais são ponderados por pesos, o que possibilita identificar a importância desses dados para o neurônio. Dessa forma, é realizado o processamento desses sinais de entrada por meio do somatório da multiplicação dos sinais de entrada pelos pesos.

Segundo [Julia \(2018c\)](#), o resultado desse cálculo produz um valor chamado de potencial de ativação do neurônio. Caso o potencial de ativação do neurônio supere um determinado limiar, o potencial será excitatório. Caso contrário, tal potencial será inibitório. Esse valor é utilizado como parâmetro de uma função de ativação, também conhecida como função de transferência, que gera uma determinada saída para o neurônio. Tal função tem como objetivo limitar o sinal de saída do neurônio a valores adequados ao problema que está sendo tratado pelo sistema neural. Na Figura 1, temos esse processo exemplificado por meio do modelo proposto por [\(MCCULLOCH; PITTS, 1943\)](#), onde os  $x_i$ 's são os sinais de entrada recebidos pelo neurônio, e os  $w_{ji}$ 's são os pesos que ponderam a intensidade desses sinais. O neurônio realiza o processamento por meio do somatório da multiplicação das entradas pelos pesos produzindo o potencial de ativação que é passado para função de transferência, gerando assim a saída do neurônio.

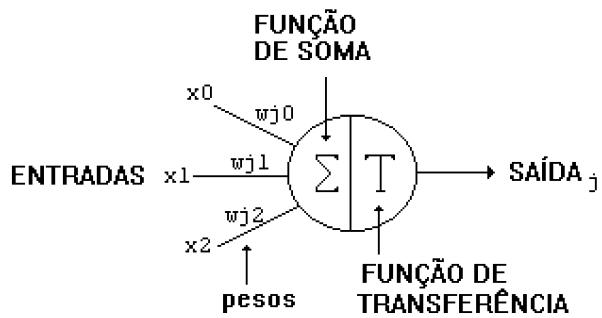


Figura 1 – Exemplo de um neurônio artificial. Imagem obtida em [Tafner \(1998\)](#)

## 2.1.2 Função de ativação

Conforme explicado na subseção anterior, a função de ativação é responsável por receber o potencial de ativação e utilizá-lo como parâmetro para produção da saída do neurônio. Em outras palavras, ela é quem decide se o neurônio será ativado ou não. No desenvolvimento desse trabalho, foram utilizadas as seguintes funções de ativação: unidade linear retificada e *softmax*.

### 2.1.2.1 Função unidade linear retificada

A função unidade linear retificada é definida na Eq. 2.1 e o respectivo gráfico pode ser observado na Figura 2.

$$f(x) = \begin{cases} 0, & \text{se } x < 0 \\ x, & \text{se } x \geq 0 \end{cases} \quad (2.1)$$

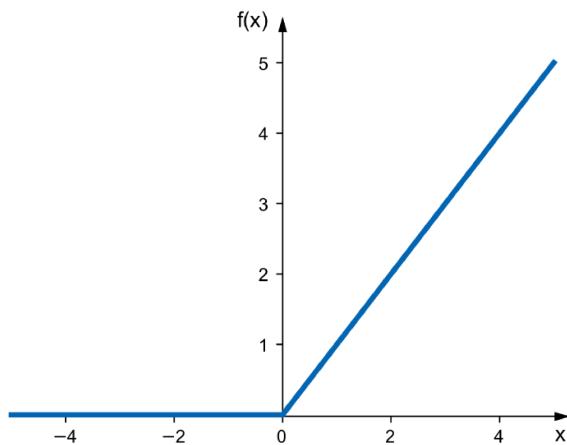


Figura 2 – Gráfico da função unidade linear retificada. Imagem obtida em [\(RACHKA, 2018\)](#)

### 2.1.2.2 Função *softmax*

Segundo [Sterbak \(2017\)](#), a função *softmax*, descrita na Eq. 2.2, recebe um elemento de um vetor K-dimensional com valores reais arbitrários e o transforma em um elemento de um novo vetor K-dimensional de valores reais no intervalo [0,1]. Essa função é uma escolha comum em problemas de classificação em múltiplas classes. No contexto de redes neurais, ela irá retornar a probabilidade de uma determinada classe dentro de um problema de multi-classificação.

Para i de 1 até k faça:

$$\text{Softmax}(vi) = \frac{e^{vi}}{\sum_{i=1}^k e^{vi}} \quad (2.2)$$

onde cada  $vi$  é um elemento do vetor original, além de k ser o tamanho do vetor.

### 2.1.3 Rede neural artificial *perceptron*

A rede neural artificial *perceptron*, foi idealizada por ([ROSENBLATT, 1958](#)), com sua utilização voltada para tratar de problemas de classificação, alocando padrões de entradas em grupos. Ela é uma técnica de aprendizado supervisionado e possui a seguinte arquitetura : camada de nodos de entrada e camada de neurônios artificiais processadores. A camada de entrada é responsável por receber os dados e passá-los para as camadas subsequentes. Os neurônios entre as camadas estão conectados e essas conexões são ponderadas por pesos que indicam a intensidade desses *links*. Na Figura 3, temos o exemplo de uma rede que possui quatro entradas, uma camada intermediária possuindo três neurônios e a camada saída contendo dois neurônios.

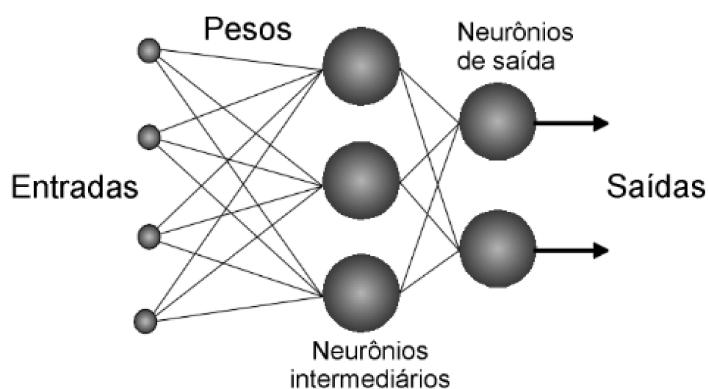


Figura 3 – Exemplo de uma rede neural. Imagem obtida em ([TAFNER, 1998](#))

### 2.1.4 Processo de aprendizagem em redes neurais

Segundo ([JULIA, 2018b](#)), no processo de aprendizagem de uma rede neural, as saídas produzidas são comparadas com as saídas reais do problema. Caso sejam diferentes, esse erro obtido é utilizado para realizar a atualização do vetor de pesos da rede neural em um processo conhecido como *backpropagation*.

Um outro parâmetro utilizado no ajustes dos pesos de uma rede neural é a taxa de aprendizagem. Ela é um valor dentro do intervalo  $]0,1[$  que exprime o quanto rápido será o processo de aprendizagem. De acordo com ([SILVA, 2019](#)) e ([ROSA, 2019](#)), quanto menor esse valor, mais lento será o processo de aprendizagem, pois haverá um ajuste mais suave do vetor de pesos, entretanto isso permitirá uma maior estabilidade na convergência do processo de aprendizado. Por outro lado, valores maiores permitem uma aprendizagem mais rápida, porém com uma tendência maior à instabilidade.

De acordo com ([CARVALHO, 2019](#)), o processo de aprendizagem pode possuir dois critérios de parada: número de iterações ou limiar de erro estabelecido. Dessa forma, tal processo pode ser repetir até que um número de iterações sejam executadas, também conhecidas como épocas dentro do contexto de redes neurais. Da mesma forma, o processo de aprendizagem pode ocorrer até que o erro obtido em uma determinada época seja menor do que um limiar de erro estipulado.

Após a realização do treinamento, os pesos da rede neural em todas as camadas são atualizados e dessa forma podemos utilizá-la para realização de testes.

## 2.2 Problema de otimização

Nos problemas de otimização, busca-se maximizar ou minimizar uma função que possui uma ou mais variáveis, sendo que existe um conjunto de restrições que devem ser respeitadas.

A formulação geral de um problema de otimização possui o seguinte padrão como pode ser identificado na Figura 4.

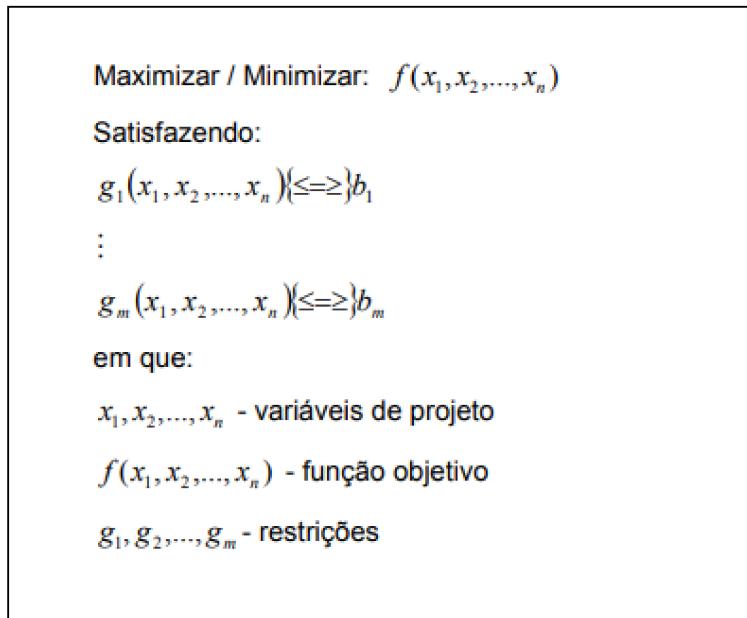


Figura 4 – Modelagem de um problema de otimização. Imagem obtida em ([PUCRIO, 2019](#))

Um problema de otimização pode ser solucionado com a utilização de métodos probabilísticos ou determinísticos. Na seção subsequente, será apresentado um método probabilístico utilizado que é o algoritmo genético.

## 2.3 Algoritmos genéticos

Os algoritmos genéticos foram desenvolvidos por ([HOLLAND, 1975](#)) e segundo [Goldberg \(1989\)](#) são algoritmos de busca heurística adaptativa baseados nas ideias evolucionárias da seleção natural e da genética natural. Essa técnica se apresenta como uma alternativa útil quando não se conhece um algoritmo convencional eficaz para resolução de um problema em que há um grande espaço de busca.

De acordo com [Julia \(2018a\)](#), um algoritmo genético pode ser entendido como um procedimento iterativo no qual é mantido um conjunto de estruturas que são candidatas à solução de um problema.

### 2.3.1 Conceitos básicos

**Indivíduo:** cada ponto no espaço de busca do problema é representado no sistema através de uma estrutura chamada cromossomo.

**Geração:** indica a iteração na qual o algoritmo genético se encontra.

**População:** conjunto de indivíduos em uma determinada geração.

**Fitness/Aptidão:** avaliação do indivíduo.

**Função de avaliação:** avalia o quanto próximo um indivíduo está de ser a solução do problema.

### 2.3.2 Operadores genéticos

Nesta subseção, serão apresentados os operadores genéticos utilizados para geração de novos indivíduos.

#### 2.3.2.1 Seleção dos pais

Para a geração de novos indivíduos, é necessária a seleção dos pais a fim de realizar o processo de reprodução. Existem alguns métodos para essa escolha como o método do truncamento, torneio e roleta. No desenvolvimento deste trabalho, foi utilizado o método da roleta, pois é o método mais comum de seleção de pais utilizado em algoritmos genéticos.

A população é ordenada com base no *fitness* dos indivíduos. Posteriormente, percorre-se a população onde é realizada a soma das avaliações de todos os indivíduos. É realizado o sorteio de um valor dentro dessa soma global que corresponde à posição na roleta do indivíduo. Perceba que os melhores indivíduos possuem uma maior probabilidade de serem selecionados, enquanto os outros indivíduos também participam normalmente dessa escolha. Note que esse processo deve ser executado duas vezes para que dois pais sejam selecionados.

O processo de seleção dos pais pelo método da roleta pode ser exemplificado na Figura 5.

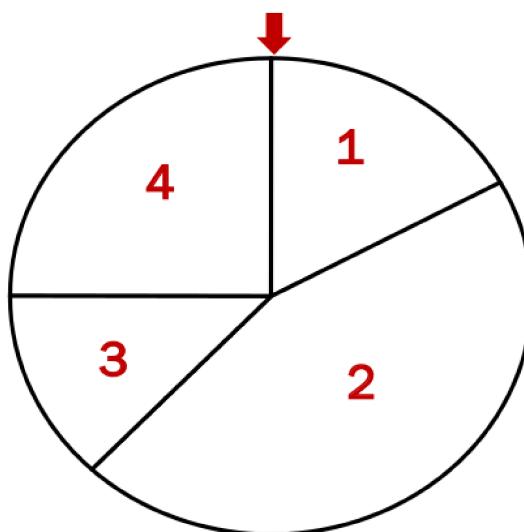


Figura 5 – Método da roleta. Imagem obtida em [Oliveira \(2018\)](#)

### 2.3.2.2 Reprodução

Após a etapa de seleção dos pais, é possível realizar o processo reprodução. Nessa etapa, é definido como será realizada a combinação dos genes dos pais para geração dos filhos. Existem algumas técnicas como, por exemplo, o *crossover simples*, *crossover múltiplo* e o *crossover uniforme*. Um parâmetro que deve ser definido no algoritmo genético é a taxa de cruzamento. Para este trabalho, foi utilizada a taxa de 100%, ou seja, após uma execução do algoritmo genético em uma determinada geração, é gerada uma nova população com a mesma quantidade de indivíduos que a população anterior. No desenvolvimento deste trabalho, por restrições de tempo para conclusão da monografia, foi implementada a técnica de *crossover simples*.

Inicialmente, é sorteado um ponto de corte a partir do qual serão combinadas as informações dos pais para geração dos filhos. Esse processo é exemplificado na Figura 6.

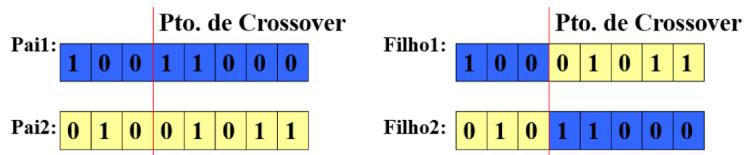


Figura 6 – Crossover simples. Imagem obtida em [Oliveira \(2018\)](#)

### 2.3.2.3 Mutação

Após a geração dos filhos, eles são submetidos à operação de mutação. Segundo [Julia \(2018a\)](#), na operação de mutação, um ou mais genes do cromossomo são alterados, modificando-os pelo seu complemento binário. A taxa de mutação pode ser dada por indivíduo ou por gene.

No desenvolvimento deste trabalho, a implementação da mutação se dará pela taxa de mutação por gene. Para cada indivíduo gerado, seu cromossomo é percorrido e, para cada posição, é sorteado um número aleatório. Caso esse valor seja menor que a taxa de mutação, o gene em questão é alterado. Caso contrário, não é realizada essa modificação genética no indivíduo. Para este trabalho, será fixada a taxa de mutação em 5%, a qual deve ser um valor pequeno para simular o que ocorre de maneira análoga no processo de evolução na natureza. Na Figura 5, pode ser visto um exemplo desse processo.

### 2.3.2.4 Escolha da nova população

Após a realização das operações de reprodução e mutação, é necessário definir a população que fará parte da geração seguinte. Nesse sentido, existem alguns métodos como o elitismo, além da reinserção pura e uniforme. Por restrições relativas a tempo de desenvolvimento do trabalho, será utilizada na implementação do algoritmo genético a

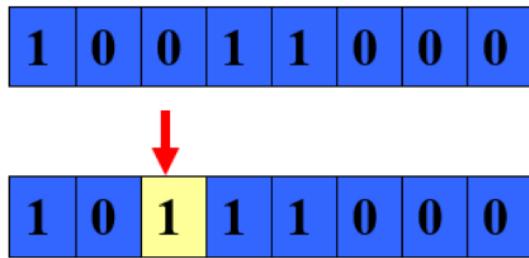


Figura 7 – Mutação. Imagem obtida em Oliveira (2018)

estratégia de reinserção pura, na qual toda a população antiga é substituída pelos filhos gerados.

### 2.3.3 Funcionamento do algoritmo genético

Nesta subseção, será apresentado o funcionamento de um algoritmo genético conforme Julia (2018a).

1. Gerar a população inicial de indivíduos.
2. Avaliar os indivíduos da população inicial.
3. Enquanto não for atingido o critério de término faça:
  - a) Selecionar  $p_{sel}$  indivíduos que formarão pares de *crossover*.
  - b) Para cada par de pais, gerar um par de filhos.
  - c) Submeter os novos indivíduos a uma mutação com probabilidade  $p_{mut}$
  - d) Avaliar os novos indivíduos.
  - e) Definir população que será levada para próxima geração.
4. Melhor indivíduo é apresentado como solução.

## 2.4 Boxplot

Segundo Faria (2018), o *boxplot* ou diagrama de caixa é uma ferramenta estatística que permite a visualização da distribuição dos dados, além de permitir a identificação de valores discrepantes, fornecendo assim uma maneira para se desenvolver uma perspectiva sobre o caráter dos dados. Em seguida, será exibida a Figura 8 que mostra a composição do *boxplot*.

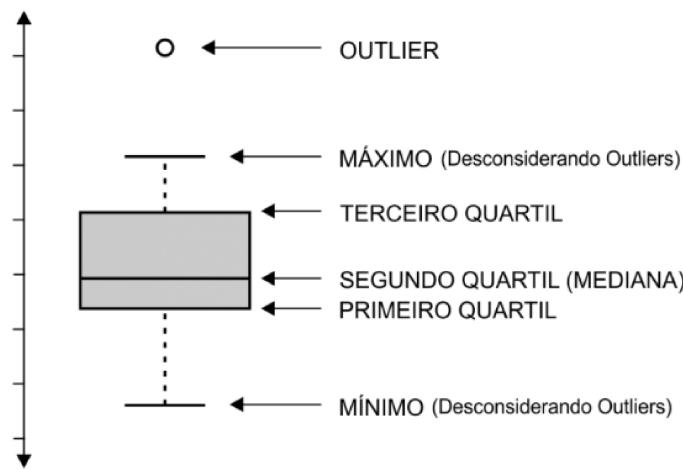


Figura 8 – Composição de um *boxplot*. Imagem obtida em [Faria \(2018\)](#)

**Mínimo:** É o valor mínimo de um *boxplot*. Essa medida é utilizada na detecção de *outliers*. Ela pode ser obtida da seguinte maneira:

$$\text{Mínimo} = \text{Primeiro Quartil} - 1.5 * (\text{Terceiro Quartil} - \text{Primeiro Quartil})$$

**Primeiro quartil:** É o valor de um *boxplot* tal que 25% dos dados estão abaixo dele.

**Segundo quartil:** Também conhecida como mediana, é o valor de um *boxplot* tal que 50% dos dados estão abaixo dele.

**Terceiro quartil:** É o valor de um *boxplot* tal que 75% dos dados estão abaixo dele.

**Máximo:** É o valor máximo de um *boxplot*. Assim como o mínimo, esse valor também serve como um limite para mapeamento de *outliers*. Ele pode ser obtida da seguinte maneira:

$$\text{Máximo} = \text{Terceiro Quartil} + 1.5 * (\text{Terceiro Quartil} - \text{Primeiro Quartil})$$

**Outliers:** Os *outliers* são considerados valores discrepantes no *boxplot*, pois estão acima ou abaixo dos valores de mínimo e máximo.

## 2.5 Cartola FC

O CartolaFC é um *fantasy game* que existe desde 2005, sendo mantido pelo Globoesporte,<sup>1</sup> no qual é possível escalar, ao longo de cada uma das 38 rodadas, um time de futebol com os atletas e treinadores das equipes participantes da série A do campeonato brasileiro.

<sup>1</sup> <https://globoesporte.globo.com/>

### 2.5.1 Regras do jogo

Após o processo de cadastro, o cartoleiro pode escalar seu time, com um total de 100 cartoletas, que é a moeda virtual utilizada para realizar as operações de negociação de jogadores. Inicialmente, cada atleta e treinador é precificado pela equipe criadora do jogo e seu preço aumenta ou diminui com base em sua *performance* mensurada por meio de suas pontuações obtidas ao longo dos jogos disputados no campeonato. A pontuação de cada jogador em uma rodada é calculada com base no somatório das estatísticas definidas pelo game. Também chamada de *scouts*, essas estatísticas são armazenadas e atualizadas a cada rodada, sendo importantes para o processo de tomada de decisão do time a ser escalado. Segundo [Globo \(2018\)](#), nas Tabelas 1 e 2, podem ser observadas os pesos associados aos *scouts* definidos pela regras do jogo.

Tabela 1 – Scouts de defesa

Estatística	Peso
Jogo sem sofrer gol	5.0
Defesa de pênalti	7.0
Defesa difícil	3.0
Roubada de bola	1.5
Gol contra	-5.0
Cartão vermelho	-5.0
Cartão amarelo	-2.0
Gol sofrido	-2.0
Falta cometida	-0.5

Tabela 2 – Scouts de ataque

Estatística	Peso
Gol	8.0
Assistência	5.0
Finalização na trave	3.0
Finalização defendida	1.2
Finalização para fora	0.8
Falta sofrida	0.5
Pênalti perdido	-4.0
Impedimento	-0.5
Passe errado	-0.3

Para exemplificar o processo de pontuação dos jogadores, suponha que um jogador em uma partida tenha feito dois gols e cometido duas faltas. Dessa forma, sua pontuação será  $2*(8) + 2*(-0.5) = 16 - 1 = 15$  pontos. O resultado obtido pelo time escolhido ao final de cada rodada será a soma das pontuações individuais dos 11 atletas mais a do treinador que é um caso particular, pois sua pontuação é resultado da média da pontuação do time do qual ele é técnico. Por exemplo, a pontuação do técnico Luís Felipe Scolari será obtida

por meio do cálculo da média de todos os jogadores do Palmeiras que jogaram em uma determinada rodada. Além disso, no ano de 2018, foi incluída uma nova regra jogo, na qual é escolhido um jogador para ser o capitão do time. Esse atleta terá o número de pontos dobrado ao final da rodada.

Antes do início de cada rodada, há o momento no qual o mercado fica aberto para que os cartoleiros possam realizar a montagem do time, escalando 11 jogadores e um treinador, dentro do limite de seu patrimônio. Dessa forma, o objetivo do jogo consiste em acumular a maior quantidade de pontos ao longo de todas as rodadas do campeonato brasileiro.

#### 2.5.1.1 Esquema tático

Além disso, no momento da montagem do time, o cartoleiro deverá optar pelas opções de esquema tático oferecidos. De acordo com a opção escolhida, existe a restrição da quantidade de jogadores por posição que podem ser escalados.

Para o CartolaFC, temos os 7 esquemas táticos possíveis mencionados a seguir:

**4-3-3:** essa formação é composta por 4 defensores. Quando a formação possui 4 defensores, isso significa que dois jogadores dessa linha defesa são zagueiros e os outros dois são laterais. Além disso, existem 3 meio-campistas e 3 atacantes.

**4-4-2:** essa formação é composta por 4 defensores, além de possuir 4 meio-campistas e 2 atacantes.

**4-5-1:** essa formação é composta por 4 defensores, além de possuir 5 meio-campistas e 1 atacante.

**3-5-2:** essa formação é composta por 3 defensores. O esquema tático que possui 3 defensores, não possui laterais, apenas zagueiros. Além disso, existem 5 meio-campistas e 2 atacantes.

**3-4-3:** essa formação é composta por 3 defensores, 4 meio-campistas, além de 3 atacantes.

**5-3-2:** essa formação é composta por 5 defensores. Quando a formação possui 5 defensores, isso significa que 3 jogadores dessa linha de defesa são zagueiros e os outros 2 são laterais. Além disso, existem 3 meio-campistas e 2 atacantes.

**5-4-1:** essa formação é composta por 5 defensores. Além disso, existem 4 meio-campistas e 1 atacante.

Observe que na descrição do esquema tático não foi mencionado o goleiro nem o técnico, pois em todo esquema tático existe apenas um goleiro e um técnico.

### 2.5.1.2 Status dos atletas

Uma outra questão que deve ser levada em consideração no processo de escolha do time, é observar o status de cada um dos atletas. No CartolaFC, existem 5 possíveis status, que estão descritos a seguir:

**Provável:** é provável que o jogador seja escalado para jogar na rodada em questão.

**Contundido:** esse status indica que o jogador está machucado e por esse motivo, possivelmente não estará em campo.

**Dúvida:** é incerta a participação do jogador na rodada. Isso pode ocorrer por vários motivos como por exemplo, quando não se tem convicção se o jogador será escalado como titular ou reserva, ou ainda, por mistério do treinador do time que não deseja revelar sua escalação.

**Suspenso:** o jogador não será relacionado para jogar nessa rodada, pois está suspenso. Isso ocorre em virtude de alguma punição que ele tenha sofrido como, por exemplo, um cartão vermelho no jogo anterior ou três cartões amarelos.

**Nulo:** esse status se aplica aos jogadores que não estão relacionados para a rodada.

## 2.6 Trabalhos relacionados

Técnicas de aprendizado de máquina estão sendo utilizadas em trabalhos de pesquisa para predição de pontuações em *fantasy games* de diversas modalidades esportivas tais como o futebol, basquete e futebol americano, utilizando-se de estatísticas do histórico de desempenho dos atletas.

### 2.6.1 Machine Learning Applications in Fantasy Basketball

O trabalho de (HERMANN; NTOSO, 2015) utiliza estratégias de aprendizado de máquina para predição de pontuações de jogadores da liga de basquetebol americana, no *fantasy game DraftKings*. Segundo Hermann e Ntoso (2015), foi utilizado um modelo de regressão linear tendo como base o histórico de desempenho dos jogadores. Finalmente, após realizar a construção de um algoritmo para predição da pontuação dos jogadores a cada rodada, a escalação do time foi realizada, utilizando-se a modelagem de um problema de satisfação de restrições, levando-se em consideração o patrimônio disponível para escalar. Inicialmente, para montagem da combinação ótima do time, foi utilizado o algoritmo de busca *Backtracking*. Entretanto, por apresentar uma alta complexidade de execução  $O(n^8)$  em tempo, foi utilizado o algoritmo *Beam Search*, que apesar de não garantir a solução ótima, encontra rapidamente uma escalação com uma pontuação alta em complexidade de tempo  $O(n \log(n))$ .

### 2.6.2 Fantasy Football Projection Analysis

O trabalho de (DUNNINGTON, 2015) tem como objetivo realizar a análise e a combinação de projeções semanais de diversas fontes de dados referentes à pontuação dos jogadores da liga de futebol americano dos Estados Unidos para o *fantasy game FanDuel*, na construção de um modelo que consiga aumentar a acurácia das previsões. Segundo Dunnington (2015), foi construído um sistema que realiza a escolha dos jogadores utilizando-se de técnicas de regressão linear, sendo realizada uma análise abrangente das projeções da temporada de 2014. As conclusões deste trabalho sugerem que a agregação de projeções profissionais de pontuação pode produzir ligeiros aumentos na acurácia das previsões.

### 2.6.3 Aplicação de aprendizado de máquina para otimização da escalação de time no jogo CartolaFC

O trabalho de (VISCONDI; GARCIA; JUSTO, 2017) utilizou-se de três algoritmos de aprendizagem de máquina para predizer a pontuação dos atletas do jogo CartolaFC. Segundo Visconti, Garcia e Justo (2017), foi utilizada a técnica de aprendizado não supervisionado *K-Means* para clusterização do conjunto de dados, pois estima-se que se agrupando os jogadores com comportamentos semelhantes, pode-se obter melhores resultados na hora de predizer suas pontuações. Posteriormente, foram aplicados os seguintes algoritmos para predição: *Extreme Gradient Boosting*, *Random Forest* e *Support Vector Machine*. Além disso, foi realizada a comparação dos resultados da utilização de cada um dos algoritmos com diversos esquemas táticos. Para treinamento do modelo, foram utilizadas as primeiras 28 rodadas da série A do Campeonato Brasileiro de Futebol de 2017. Por outro lado, para realização de testes, foram usadas as 5 rodadas subsequentes. Os resultados do trabalho sugerem que o algoritmo *Random Forest* superou os algoritmos de *Support Vector Machine* e *Extreme Gradient Boosting* na escalação dos times.

### 2.6.4 Ciência de dados aplicada na predição de escalação de equipes para o jogo CartolaFC

O trabalho de (LIMA; PASQUINI; TRAVIZAN, 2018) utilizou-se de três algoritmos para realizar a predição da pontuação para escalação de atletas no jogo CartolaFC. Segundo Lima, Pasquini e Travizan (2018), após a etapa de pré-processamento de dados para criação do modelo, foram utilizados os seguintes algoritmos: algoritmo baseado em escolha aleatória, algoritmo baseado em média e o algoritmo baseado em árvore de regressão simples. A estratégia aleatória consiste em selecionar aleatoriamente os jogadores para uma rodada. Por outro lado, a estratégia baseada em média, seleciona os jogadores que possuem as maiores médias até o momento. Finalmente, a estratégia baseada em árvore de

regressão seleciona a escalação a partir do modelo definido. Os resultados sugerem que a construção de um modelo para predição das escalações é melhor comparada às estratégias baseadas na média ou aleatória.

# 3 Desenvolvimento

Nesse capítulo, será apresentado todo o desenvolvimento da pesquisa realizada, desde a padronização da base de dados, até a construção do algoritmo genético responsável pela escalação dos times.

## 3.1 Base de dados do CartolaFC

Os dados utilizados para o desenvolvimento desse trabalho foram retirados de um repositório no *GitHub* chamado caRtola. Segundo [Gomide \(2019\)](#), esse repositório tem como finalidade disponibilizar todos os dados do CartolaFC desde sua criação em 2014. Dessa forma, os dados estão organizados em diretórios separados por ano, em arquivos de extensão 'csv', contendo as estatísticas relativas ao histórico de desempenho dos atletas. Para realizar o *download* dos dados disponíveis no repositório, basta digitar no terminal do *Linux* o comando: `git clone https://github.com/henriquepgomide/caRtola`

### 3.1.1 Pré-processamento

Uma primeira etapa no desenvolvimento desse trabalho foi conseguir padronizar os dados de 2014 a 2019, que são as estatísticas mencionadas nas Tabelas 1 e 2 da Seção 2.5.1, pois se encontravam em um formato diferente em cada ano. Nessa etapa, foi realizada a representação do histórico das estatísticas dos atletas por meio de médias, pois como algumas colunas apresentavam grande variabilidade de valores, utilizar a soma das estatísticas dos atletas como entrada no processo de classificação de jogadores, que será realizado por uma rede neural, poderia não ser uma boa alternativa. Dessa maneira, a utilização da representação das estatísticas por médias se apresenta como uma forma de padronização dos dados.

Dessa forma, após a etapa de pré-processamento de dados, foram gerados arquivos com as médias das estatísticas dos jogadores por ano contendo as seguintes colunas:

**Apelido:** apresenta o apelido do jogador/técnico.

**Posição:** informa qual a posição do jogador no time. Foram utilizados números para identificação das posições. Para goleiro, foi utilizado o número 1, para lateral o número 2, para zagueiro o número 3, para meio-campista o número 4, para atacante o número 5 e para técnico o número 6.

**Preço:** mostra o preço do jogador/técnico

**PontosMedia:** média de pontos do jogador/técnico.

**A:** média do número de assistências.

**CA:** média do número de cartões amarelos.

**FC:** média do número de faltas cometidas.

**FD:** média do número de finalizações defendidas.

**FF:** média do número de finalizações para fora.

**FS:** média do número de faltas sofridas.

**FT:** média do número de finalizações na trave.

**G:** média do número de gols realizados.

**GC:** média do número de gols contra feitos.

**I:** média do número de impedimentos.

**PE:** média do número de passes errados.

**RB:** média do número de roubadas de bola.

**SG:** média do bônus de 5 pontos de pontuação aplicado aos jogadores de defesa (goleiros, laterais e zagueiros) nos jogos em que o time não tomou gols. Essa coluna é responsável por trazer o número de jogos em que o time de determinado jogador não sofreu gols e o jogador ganhou esse bônus de pontuação.

**CV:** média do número de cartões vermelhos.

**DD:** pontuação específica para goleiros. Indica a média do número de defesas difíceis realizadas ao longo do campeonato.

**GS:** pontuação específica para goleiros. Mostra a média do número de gols sofridos.

**DP:** pontuação específica para goleiros. Mostra a média do número de pênaltis defendidos.

**PP:** média do número de pênaltis perdidos.

As estatísticas dos atletas mencionadas acima serão utilizadas como entradas na rede neural que será apresentada na Seção 3.3. Para treinamento, serão utilizados os dados de 2014 a 2018 e, para testes, serão utilizadas as rodadas 6 e 7 do ano de 2019.

Para os dados de 2014 a 2018, como o campeonato desses anos já aconteceu, o arquivo de dados referente à cada ano conterá a média das estatísticas para cada jogador naquele ano. Já para o ano de 2019, como o campeonato ainda está em curso, para realização de testes serão utilizadas as rodadas 6 e 7. Essas rodadas foram escolhidas para realização de testes, pois eram as que possuíam a maior quantidade de dados referente ao desempenho dos jogadores até o momento. Para cada rodada de teste, será utilizado o histórico de dados do jogador até a rodada anterior. Por exemplo, para predição das

escalações na rodada 6, será utilizado o histórico de dados dos jogadores desde a primeira rodada até rodada 5.

Como o técnico não é um jogador, ele não possui as estatísticas mencionadas dos atletas. Dessa forma, na etapa de pré-processamento, os técnicos foram retirados da base de dados, pois eles aparecem com os *scouts* todos zerados, exceto pelo valor da sua média de pontos.

Porém, no processo de escalação de times no CartolaFC, o técnico também deve ser escalado. Entretanto, por questões relativas à tempo de desenvolvimento do trabalho, acidentalmente, os técnicos não foram reinseridos para etapa de escalação em conjunto com os atletas. Dessa forma, para o processo de escalação serão considerados apenas os jogadores e não os técnicos.

## 3.2 Análise de dados

Após a realização do pré-processamento dos dados, foi realizada uma análise estatística utilizando *boxplots* com base no valor da média de pontuação dos jogadores. Isso irá auxiliar no processo de identificação de classes que serão utilizadas em uma etapa posterior do desenvolvimento do trabalho.

Os *outliers* foram retirados das bases de dados de cada ano, pois representavam jogadores que, em sua maioria, jogaram apenas uma vez e tiveram um aproveitamento muito bom ou muito ruim. Dessa forma, isso poderia atrapalhar, numa etapa futura, o processo de aprendizagem do modelo.

Para o ano de 2014, o valor mínimo do *boxplot* foi de -2.24, enquanto o valor do primeiro quartil foi de 0.97. Já para a mediana, foi obtido o valor de 2.125. Além disso, o valor do terceiro quartil foi de 3.35. Finalmente, o valor máximo do *boxplot* foi de 6.83. O *boxplot* pode ser visualizado na Figura 9.

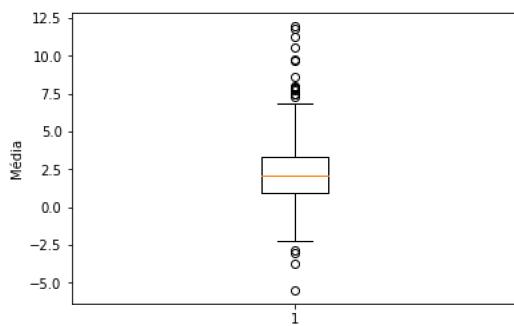


Figura 9 – *Boxplot* 2014

Para o ano de 2015, o valor mínimo do *boxplot* foi de -3, enquanto o valor do primeiro quartil foi de 1.085. Já para a mediana, foi obtido o valor de 2.4. Além disso, o

valor do terceiro quartil foi de 4.0675. Finalmente, o valor máximo do *boxplot* foi de 6.83. O *boxplot* pode ser visualizado na Figura 10.

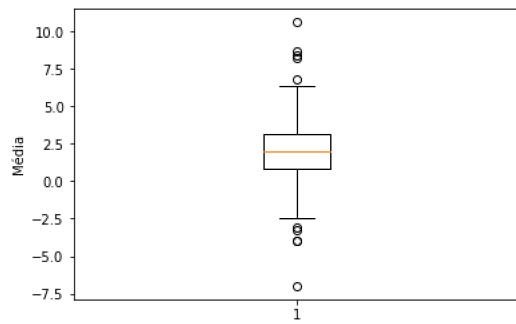


Figura 10 – *Boxplot* 2015

Para o ano de 2016, o valor mínimo do *boxplot* foi de -2.3, enquanto o valor do primeiro quartil foi de 0.9575. Já para a mediana, foi obtido o valor de 2.025. Além disso, o valor do terceiro quartil foi de 3.14. Finalmente, o valor máximo do *boxplot* foi de 6.25. O *boxplot* pode ser visualizado na Figura 11.

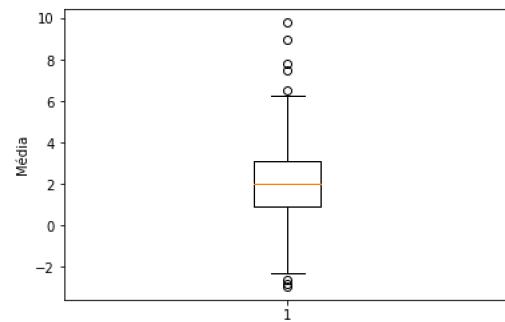


Figura 11 – *Boxplot* 2016

Para o ano de 2017, o valor mínimo do *boxplot* foi de -2, enquanto o valor do primeiro quartil foi de 1.08. Já para a mediana, foi obtido o valor de 2.23. Além disso, o valor do terceiro quartil foi de 3.45. Finalmente, o valor máximo do *boxplot* foi de 6.52. O *boxplot* pode ser visualizado na Figura 12.

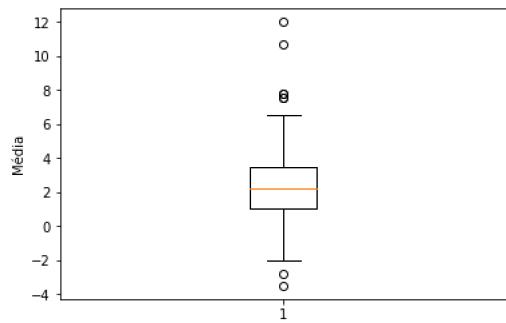


Figura 12 – Boxplot 2017

Para o ano de 2018, o valor mínimo do *boxplot* foi de -2, enquanto o valor do primeiro quartil foi de 1.305. Já para a mediana, foi obtido o valor de 2.43. Além disso, o valor do terceiro quartil foi de 3.745. Finalmente, o valor máximo do *boxplot* foi de 7.32. O *boxplot* pode ser visualizado na Figura 13.

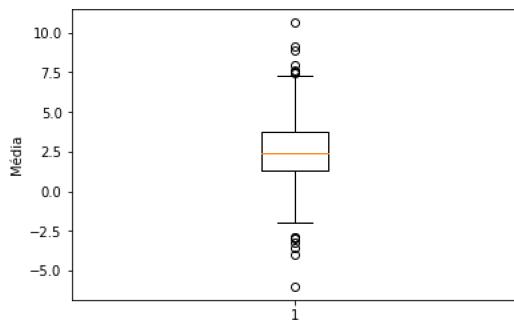
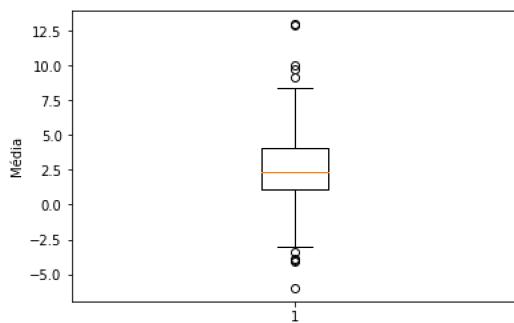


Figura 13 – Boxplot 2018

Para a rodada 6 do ano de 2019, o valor mínimo do *boxplot* foi de -3, enquanto o valor do primeiro quartil foi de 1.085. Já para a mediana, foi obtido o valor de 2.4. Além disso, o valor do terceiro quartil foi de 4.0675. Finalmente, o valor máximo do *boxplot* foi de 8.42. O *boxplot* pode ser visualizado na Figura 14.

Figura 14 – Boxplot 6<sup>a</sup> RODADA-2019

Para a rodada 7 do ano de 2019, o valor mínimo do *boxplot* foi de -3, enquanto o valor do primeiro quartil foi de 1.05. Já para a mediana, foi obtido o valor de 2.43. Além

disso, o valor do terceiro quartil foi de 3.91. Finalmente, o valor máximo do *boxplot* foi de 8. O *boxplot* pode ser visualizado na Figura 15.

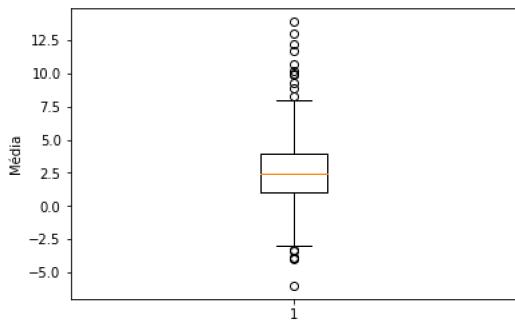


Figura 15 – *Boxplot* 7<sup>a</sup> RODADA-2019

### 3.3 Classificação dos jogadores

Com base na estrutura do próprio *boxplot*, foi proposta inicialmente a classificação dos jogadores em três classes: ruim, médio, bom. A classe ruim conterá os jogadores que possuem média de pontos maiores ou iguais ao valor mínimo do *boxplot* e menor que o valor do primeiro quartil. Já a classe médio possuirá os jogadores que contém média de pontos dentro do retângulo do *boxplot*, ou seja, com valores de média maiores ou iguais ao primeiro quartil e menores ou iguais ao terceiro quartil. Finalmente, a classe bom conterá os jogadores que estão com média de pontos acima do terceiro quartil e abaixo do valor máximo do *boxplot*.

Graficamente, a divisão das classes fica distribuída da seguinte maneira, como pode ser observado na Figura 16.

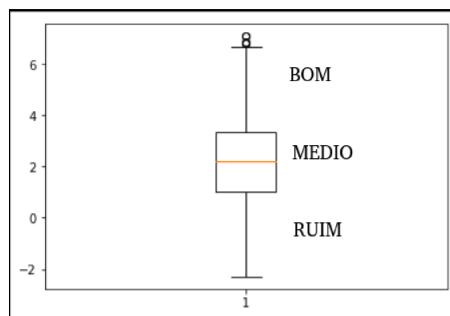


Figura 16 – Classes de jogadores

Dessa forma, foi criada uma coluna no arquivo que contém o histórico de dados dos jogadores, mostrando a qual classe eles pertencem. Por questões de facilidade de manipulação de dados, foram usados números ao invés de palavras. Para identificar a classe ruim, foi utilizado o número 0, já para a classe médio, foi utilizado o número 1, e para a classe bom, foi utilizado o número 2.

### 3.3.1 Estrutura da rede neural para classificação da flor Íris

Para realizar o processo de classificação dos jogadores, será utilizada uma rede neural *perceptron* de múltiplas camadas. Na definição da estrutura da rede neural, foi utilizado o modelo de uma outra rede usada em um problema semelhante dentro do contexto de aprendizado de máquina: a classificação de espécies da flor Íris.

O banco de dados é constituído por 150 registros contendo 5 colunas. Dessa forma, o problema consiste em, com base em quatro atributos, classificar uma determinada instância em uma classe da flor Íris: setosa, virgínica ou versicolor. Os quatro atributos previsores são o comprimento da pétala, a largura da pétala, o comprimento da sépala, largura da sépala e o atributo meta é a classe.

A rede neural que realiza essa classificação pode ser encontrada em ([KIEFFER, 2018](#)) e possui a seguinte arquitetura:

Na camada de entrada, temos os 4 atributos previsores. Além disso, a rede possui 4 camadas ocultas, onde na primeira foram escolhidos 8 neurônios, e nas camadas subsequentes, 10 neurônios. Por fim, a camada de saída possui 3 neurônios.

Com relação às funções de ativação para cada neurônio, para a camada oculta foi utilizada a função unidade linear retificada, e na camada de saída foi utilizada a função *softmax* que é uma escolha comum em problemas de classificação em mais de duas classes.

Após a definição da estrutura da rede neural, foi realizado o processo de treinamento, e após 10 épocas, a rede que classifica a flor de Íris teve uma taxa de acerto de 86,67%.

### 3.3.2 Estrutura da rede neural para classificação dos atletas

Para definir a estrutura da rede neural que classifica os jogadores nas três classes definidas na etapa de análise de dados, foi utilizada como exemplo a estrutura da rede do problema de classificação da flor de Íris. Como se trata de um problema de multi-classificação, o conhecimento prévio é que a rede neural deve possuir camadas ocultas, pois não se trata de um problema linearmente separável.

Na camada de entrada, temos 18 atributos previsores mencionados na Secção [2.5.1](#) nas Tabelas [1](#) e [2](#), que são a média das estatísticas dos jogadores. Além disso, a rede possui 4 camadas ocultas, cada uma possuindo 36 neurônios. Em comparação com o número de neurônios nas camadas ocultas da rede do problema da flor de Íris, houve um aumento nesse número, pois existem mais atributos previsores no problema de classificação dos jogadores. Já na camada de saída, temos 3 neurônios, utilizando a codificação *one-of-classes*, na qual existe um neurônio para representar cada classe. Com relação às funções de ativação, serão utilizadas as mesmas que na rede neural da flor Íris.

### 3.3.3 Treinamento da rede neural

Para implementação da rede neural foi utilizada a biblioteca *Keras* em *Python* ([KERAS, 2019](#)). Ela permite de uma maneira simples a criação de uma rede, por meio da especificação do número de camadas, número de neurônios em cada camada e funções de ativação, abstraindo toda parte de implementação do processo de aprendizagem.

Para realizar o treinamento da rede neural, foram utilizados os dados de 2014 a 2018. Após a realização da agregação das bases de dados de cada ano, a base de treinamento ficou com um total de 3499 registros.

Para treinamento da rede, foram utilizadas 1000 épocas e após esse processo, a acurácia obtida foi de 99.69%. Note que apesar do número de épocas escolhidas para treinamento ter sido fixado em 1000, aproximadamente a partir da época 600 há uma estabilização com relação à evolução da acurácia, conforme pode ser observado na Figura 17.

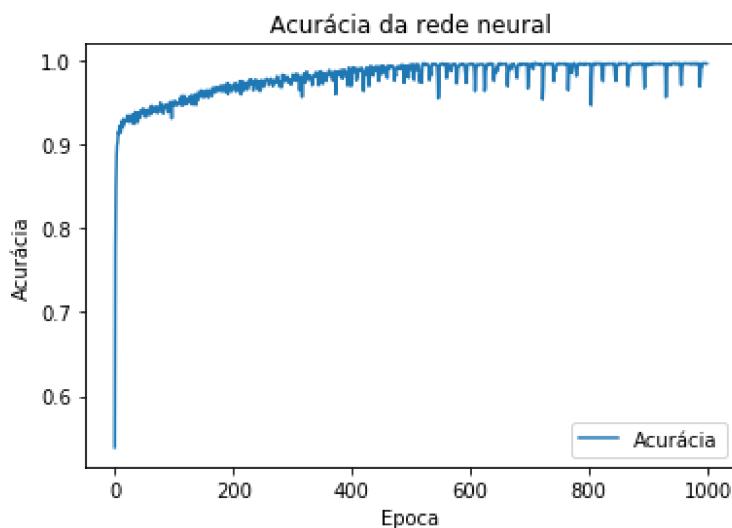


Figura 17 – Acurácia da rede neural

### 3.3.4 Testes da rede neural

Nesta subseção serão apresentados os resultados obtidos na fase de testes da rede neural.

Na sexta rodada, foi realizada a classificação de 412 jogadores. A comparação entre a classe predita pela rede neural e a classe real do jogador identificada na etapa de análise de dados pode ser observada na Figura 18.

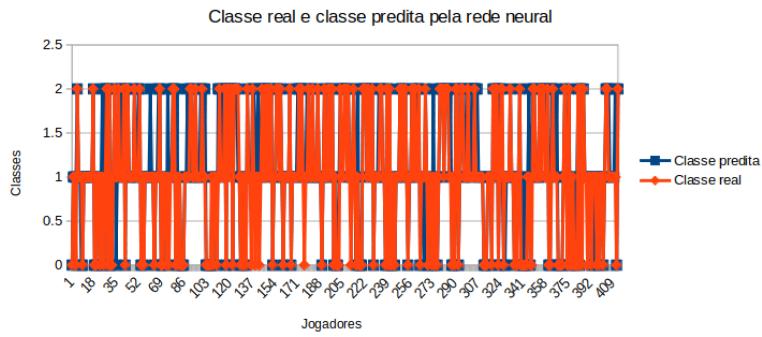


Figura 18 – Classe predita pela rede neural e classe real

Do total de 412 jogadores, 342 foram classificados corretamente quando comparados com as classificações obtidas na etapa de análise de dados e 70 obtiveram uma classificação diferente da esperada, o que mostra uma taxa de acerto de 83%. Essa queda em relação à fase de treinamento provavelmente ocorreu pois, como os dados da base de treinamento estão agregados com as estatísticas médias por ano dos atletas, e as rodadas de testes estão apenas no início do campeonato, os dados ainda não adquiriram todo o padrão aprendido pela rede neural.

Já na sétima rodada, foi realizada a classificação de 427 jogadores. A diferença no número de jogadores entre as rodadas pode ocorrer pois novos atletas podem aparecer ao longo do campeonato. A comparação entre a classe predita pela rede neural e a classe real do jogador identificada na etapa de análise de dados pode ser observada na Figura 19.

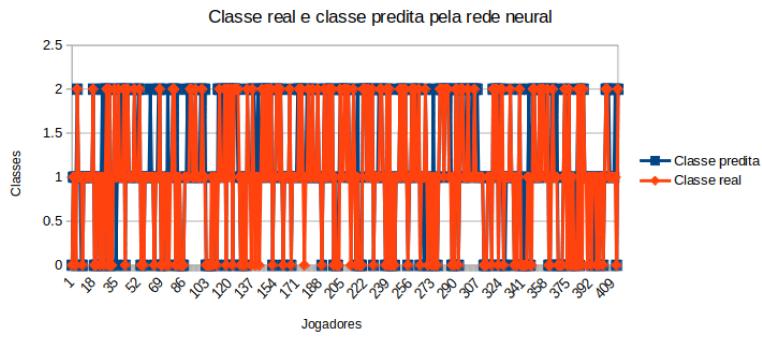


Figura 19 – Classe predita pela rede neural e classe real

Do total de 427 jogadores, 360 foram classificados corretamente quando comparados com as classificações obtidas na etapa de análise de dados e 67 obtiveram uma classificação diferente da esperada, o que mostra uma taxa de acerto de 84,30%. Da mesma forma como havia ocorrido na rodada 6, percebe-se uma diferença entre a taxa de acerto da rede neural na fase de treinamento, e na fase de testes, justamente pelo fato das rodadas de testes estarem apenas no início do campeonato, enquanto os dados utilizados no treinamento possuem as estatísticas médias dos atletas por ano. À medida que as rodadas forem acontecendo ao longo do campeonato, a tendência é que a rede neural consiga cada vez mais classificar os jogadores corretamente.

### 3.3.5 Filtragem de jogadores

Após a etapa de classificação de jogadores nas rodadas de testes, será realizada a exclusão dos jogadores que foram categorizados na classe 0, que é considerada a classe de jogadores ruins, para que o espaço de busca seja reduzido, deixando apenas os jogadores considerados médios e bons para a etapa de escalação.

Um cuidado que deve ser tomado nesse ponto é que antes de realizar a remoção dos jogadores dessa classe, deve-se verificar que nas classes remanescentes de jogadores exista uma quantidade suficiente de atletas por posição para que sempre seja possível montar um time. Dessa forma, um conjunto mínimo de jogadores que conte cole qualquer esquema tático deve possuir 1 goleiro, 2 laterais, 3 zagueiros, 5 meio-campistas, 3 atacantes, além de 1 treinador.

Após realizar a retirada dos jogadores ruins, é realizada mais uma nova filtragem dos jogadores, onde, para o processo de escalação, são mantidos apenas os atletas que possuem o status de provável em uma determinada rodada, reduzindo assim, ainda mais o espaço de busca de possíveis soluções.

## 3.4 Escalação como um problema de otimização

Após a etapa de classificação de jogadores, é necessário selecionar atletas para composição de um time. Nesse sentido, o processo de escalação no CartolaFC pode ser modelado como um problema de otimização, onde se deseja maximizar a pontuação do time escolhido, sujeito à restrição do limite de patrimônio disponível para escalação.

Na base de dados, temos para cada jogador a sua média de pontos e seu preço. Podemos utilizar, como forma de predizer a pontuação do jogador, a sua própria média de pontos. Por exemplo, caso um jogador tenha a média de 3.74, assumiremos que ele irá fazer essa pontuação na próxima rodada. Entretanto, conforme mencionado na Seção 2.5, a partir do ano de 2018, foi inserida uma nova regra na qual é possível selecionar um jogador como capitão do time, o qual terá sua pontuação dobrada. Dessa forma, no desenvolvimento desse trabalho, após a geração do time, é selecionado como capitão o jogador com a maior média de pontos dentre todo o time escalado. Dessa forma, a pontuação predita do capitão será dobrada. Por exemplo, caso ele tenha uma pontuação predita de 5.5, sua nova pontuação por ser o capitão será de 11 e isso será contabilizado no momento de calcular a pontuação do time. Assim, a Eq. 3.1 define a função  $f(x)$ , que retorna a pontuação do time escolhido.

$$f(x) = \sum_{n=0}^{10} pontuacao(x_i) \quad (3.1)$$

O termo  $pontuacao(x_i)$  se refere à pontuação jogador  $x_i$ . Como um time tem 11 jogadores, essa função irá somar as pontuações preditas de cada um dos jogadores, para composição da pontuação do time.

Por outro lado, é necessária a contabilidade do preço do time, pois sempre há restrição com relação ao limite de patrimônio disponível para escalação. Dessa forma, a função  $g(x)$  que calcula o valor do time é dada pela Eq. 3.2.

$$g(x) = \sum_{n=0}^{10} valor(x_i) \quad (3.2)$$

O termo  $valor(x_i)$  se refere ao valor do jogador  $x_i$ . Como um time tem 11 jogadores, essa função irá somar os preços de cada um dos jogadores, para a composição do preço do time.

Conforme mencionado, existe a restrição de patrimônio para escalação de um time no CartolaFC. Essa limitação pode ser colocada dentro do processo de modelagem de um problema de otimização como uma constante  $b$  que limitará  $g(x)$ . Portanto, a modelagem do problema da escalação foi definida de acordo com Eq. 3.3.

$$\begin{aligned} & \text{maximizar } f(x) \\ & \text{sujeito a} \\ & \quad g(x) \leq b, \end{aligned} \quad (3.3)$$

onde  $f(x)$  é a função objetivo, isto é, a pontuação do time,  $g(x)$  calcula o valor do time e  $b$  é o limite de patrimônio.

### 3.5 Escalação de times

Para a escalação dos times, foi realizada a implementação de um algoritmo genético. Sua implementação foi realizada com base nos códigos disponibilizados em um curso na plataforma de cursos *online Udemy*<sup>1</sup> chamado Algoritmos Genéticos em *Python* (**GRANATYR, 2019a**), ministrado por Jones Granatyr (**GRANATYR, 2019b**).

Para execução do algoritmo genético, empiricamente foi fixada a taxa de cruzamento em 100%, a taxa de mutação em 5%, o número de gerações em 4 e o tamanho da população em 500. Foram escolhidas poucas gerações devido ao custo de processamento de um algoritmo genético e a limitação de tempo disponível para realização do trabalho. O tempo de execução do algoritmo possui aproximadamente 20 minutos com essas configurações. Nas próximas subseções, será apresentada a maneira pela qual foi definido o indivíduo e a função de avaliação dentro do algoritmo genético.

---

<sup>1</sup> <https://www.udemy.com/>

### 3.5.1 Representação do indivíduo

Como o objetivo é identificar times que tenham bom desempenho e sabendo que um time de futebol é um conjunto de 11 jogadores restritos a um esquema tático, cada indivíduo é um time. Assim, na representação do indivíduo, os jogadores estão dispostos no time obedecendo à ordem crescente de número das suas posições, definida na seção 3.1.1. Primeiramente, da esquerda para a direita na representação, aparece o goleiro que tem o número 1, depois os laterais (caso existam no esquema tático mencionado) identificados pelo número 2, e assim sucessivamente até os atacantes que possuem o número 5. A Tabela 3 mostra um exemplo de um time com esquema tático 4-3-3, onde tem-se o nome do jogador seguido pela respectiva posição.

Tabela 3 – Escalação de um time

Jogador	Posicao
Cássio	1
Carlinhos	2
Egídio	2
Emerson Santos	3
Yago	3
Rodrigo Lindoso	4
Soteldo	4
Thiago Galhardo	4
João Pedro	5
Lourenço	5
Rildo	5

Essa foi uma maneira adequada para modelagem do indivíduo, pois garante que na realização do *crossover* entre times do mesmo esquema tático, o conceito de time não seja violado. Uma outra observação é que as operações de cruzamento são realizadas apenas entre times que possuem o mesmo esquema tático, justamente para que o resultado do *crossover* entre dois times não produza um conjunto de 11 jogadores que não seja um time.

### 3.5.2 Função de avaliação

A função de avaliação do indivíduo a ser utilizada é a pontuação predita do time conforme mencionado na modelagem formal do problema. Quanto maior o valor dessa pontuação, melhor é a avaliação do indivíduo. Entretanto, como a escolha do time está restrita ao esquema tático, caso um time tenha uma pontuação predita alta, porém não esteja dentro do limite de patrimônio pré-estabelecido, essa não é uma possível solução do problema, sendo necessário dessa forma avaliar negativamente esse indivíduo. Dessa

forma, a função de avaliação é definida conforme Eq. 3.4.

$$f_{avaliacao} = \begin{cases} f(x), & \text{se } g(x) \leq b \\ 1, & \text{se } g(x) > b \end{cases} \quad (3.4)$$

A atribuição do valor 1 funciona como uma penalidade no processo de avaliação do indivíduo que não é uma possível solução do problema, pois uma nota baixa é atribuída a ele. Dessa forma, no processo de escolha da solução dentro do algoritmo genético, como a população é ordenada em ordem decrescente de pontuação, deixando nas primeiras posições os indivíduos com *fitness* mais elevados, o valor 1 é muito pequeno quando comparado às avaliações de indivíduos que são consideradas possíveis soluções. Como todo indivíduo que foi avaliado negativamente recebe a mesma nota, a ordem na qual eles irão aparecer na população após o processo de ordenação dependerá de como a função de ordenação *sorted* do Python lida com valores iguais, trocando posições ou mantendo-nas. Note que os indivíduos não são descartados, eles apenas recebem uma nota ruim, podendo dessa forma participar normalmente de processo de seleção dos pais para reprodução.

### 3.5.3 Cruzamento entre times

Na implementação do *crossover* simples, é selecionado um ponto de corte a partir do qual serão trocados os códigos genéticos dos times pais para geração dos times filhos. No desenvolvimento do trabalho, como um time terá 11 posições, numeradas de 0 a 10, o ponto de *crossover* sorteado será um número dentro desse intervalo. Na Tabela 4, segue um exemplo do funcionamento do procedimento de *crossover*. Observe que como a posição sorteada para corte foi a 6 nos pais, os jogadores foram trocados nos filhos 1 e 2.

Tabela 4 – Cruzamento entre dois times

Times pais		Corte	Times filhos	
Pai 1	Pai 2		Filho 1	Filho 2
Marcelo Lomba	Fábio		Marcelo Lomba	Fábio
Edílson	Gilson		Edílson	Gilson
Iago	Renê		Iago	Renê
Emerson Santos	Gerson		Emerson Santos	Gerson
Léo Pereira	Roger Carvalho		Léo Pereira	Roger Carvalho
Adilson	Adilson		Adilson	Adilson
Fernando Sobral	Andrey	6	Andrey	Fernando Sobral
Robinho	Didira		Didira	Robinho
Sornoza	João Paulo		João Paulo	Sornoza
Soteldo	Luan		Luan	Soteldo
Marcinho	Marrony		Marrony	Marcinho

### 3.5.4 Mutação em um time

Na implementação da mutação, um time é percorrido e caso o valor sorteado seja menor que a taxa de mutação, o jogador é retirado do time, e é realizado um sorteio dentre os outros jogadores disponíveis na base de dados para aquela posição que ainda não fazem parte do time.

Durante o processo de mutação, foram colocados comandos de impressão no algoritmo para mostrar quais jogadores foram retirados e quais os novos jogadores selecionados para composição do preço do time.

**Saiu o jogador**

**Márcio Araújo**

**Entrou o jogador**

**Rodriguinho**

Na Tabela 5, pode ser exemplificado o processo de mutação.

Tabela 5 – Mutação em um time

Time antes da mutação	Time após a mutação
Victor	Victor
Gerson	Gerson
Henrique	Henrique
Ricardo	Ricardo
Carlos Sanchez	Carlos Sanchez
Cicero	Cicero
Léo Cittadini	Léo Cittadini
Márcio Araújo	Rodriguinho
Arthur Gomes	Arthur Gomes
Nico Lopez	Nico Lopez
Pedro Rocha	Pedro Rocha

# 4 Resultados

O objetivo deste trabalho propõe um modelo para predição de escalações de times no CartolaFC, levando em consideração o esquema tático e a limitação de patrimônio disponível para escalar, utilizando aprendizado de máquina e otimização. O processo de escalação será realizado pelo algoritmo genético modelado no Seção 3.5. Dessa forma, para realização dos testes, serão utilizadas as rodadas 6 e 7 do campeonato brasileiro. Para cada rodada, foram definidos diferentes tamanhos patrimônios, sendo o primeiro mais restrito, com apenas 70 cartoletas, o segundo, com uma disponibilidade um pouco maior, contendo 100 cartoletas, e o terceiro com 150 cartoletas. Em cada uma das rodadas, foram realizados testes com todos os esquemas táticos disponíveis.

Uma observação importante é que os gráficos de evolução da pontuação dos melhores times em cada geração, apresentados em cada execução do algoritmo genético, mostram incorretamente valores intermediários no eixo horizontal como, por exemplo, 0.5, 1.5, 2.5 e 3.5. Esses valores forem gerados automaticamente pela biblioteca responsável por gerar os gráficos em *Python* chamada *matplotlib.pyplot*. Entretanto, apenas os valores inteiros são válidos e indicam a pontuação do melhor time obtido em uma determinada geração.

## 4.1 Rodada 6

Nesta seção, serão apresentados os testes realizados na 6<sup>a</sup> rodada com os limites de patrimônios mencionados utilizando todos os esquemas táticos.

### 4.1.1 Patrimônio de 70 cartoletas

Nesta subseção, serão apresentados os testes realizados com diferentes esquemas táticos para o limite de 70 cartoletas.

Para o esquema tático, 4-3-3, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 6:

Tabela 6 – Time escalado no 4-3-3 para 6<sup>a</sup> rodada

Time
Cássio
Carlinhos
Egídio
Emerson Santos
Yago
Rodrigo Lindoso
Soteldo
Thiago Galhardo
João Pedro
Lourenço
Rildo

O jogador escolhido como capitão foi Thiago Galhardo. Além disso, o preço do time é de 69.64, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 55.31 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 20 referente à evolução de pontuações das melhores soluções do algoritmo genético.

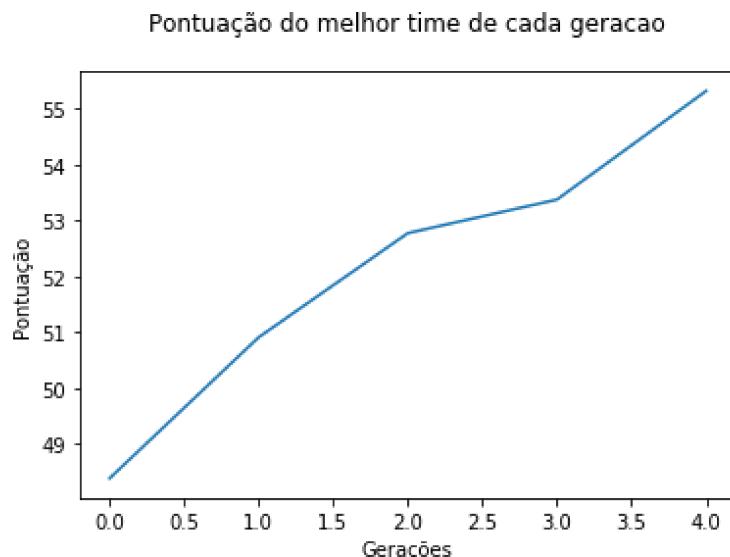


Figura 20 – Evolução da pontuação das melhores soluções

No esquema tático 4-4-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 7:

Tabela 7 – Time escalado no 4-4-2 para 6<sup>a</sup> rodada

Time
Vladimir
Carlinhos
Juninho Capixaba
Manoel
Walce
Andrey
Gegê
Lucas Mineiro
Lucas Romero
João Pedro
Rildo

O jogador escolhido como capitão foi João Pedro. Além disso, o preço do time é de 62.84, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 49 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 21 de evolução de pontuações das melhores soluções do algoritmo genético.

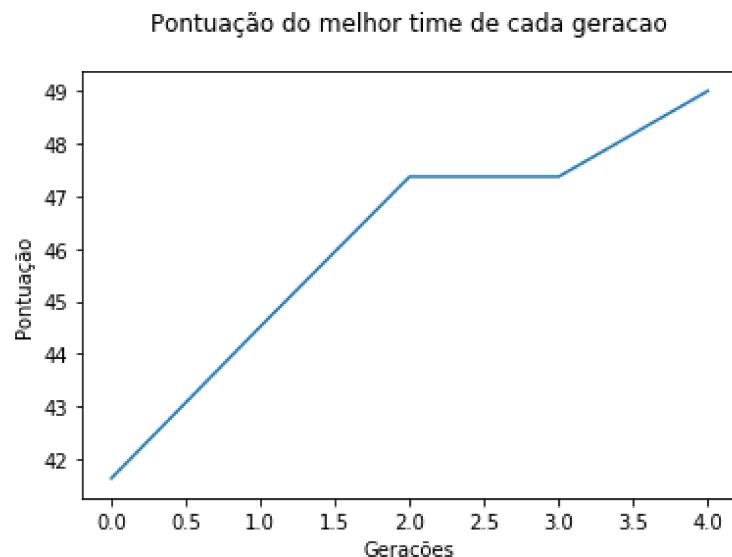


Figura 21 – Evolução da pontuação das melhores soluções

Para o esquema tático 4-5-1, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 8:

Tabela 8 – Time escalado no 4-5-1 para 6<sup>a</sup> rodada

Time
Fábio
Egídio
Igor Fernandes
Nino
Walce
Cazares
Elton
Felipe
Fernando Sobral
Sornoza
João Pedro

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 64.59, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 49.37 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 22 de evolução de pontuações das melhores soluções do algoritmo genético.

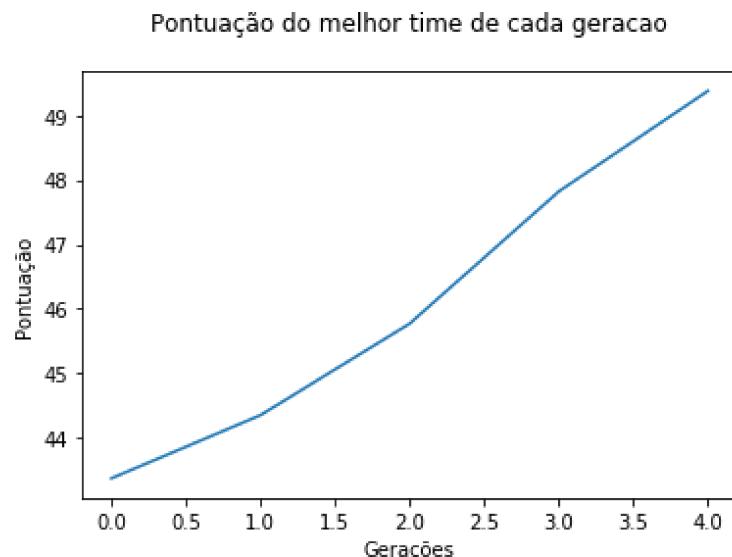


Figura 22 – Evolução da pontuação das melhores soluções

Para o esquema tático 5-4-1, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 9:

Tabela 9 – Time escalado no 5-4-1 para 6<sup>a</sup> rodada

Time
Fábio
Danilo Avelar
Gilson
Gustavo Henrique
Léo Duarte
Walce
Gabriel Dias
João Paulo
Léo Cittadini
Thiago Galhardo
João Pedro

O jogador escolhido como capitão foi Thiago Galhardo. Além disso, o preço do time é de 64.19, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 44.73 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 23 de evolução de pontuações das melhores soluções do algoritmo genético.

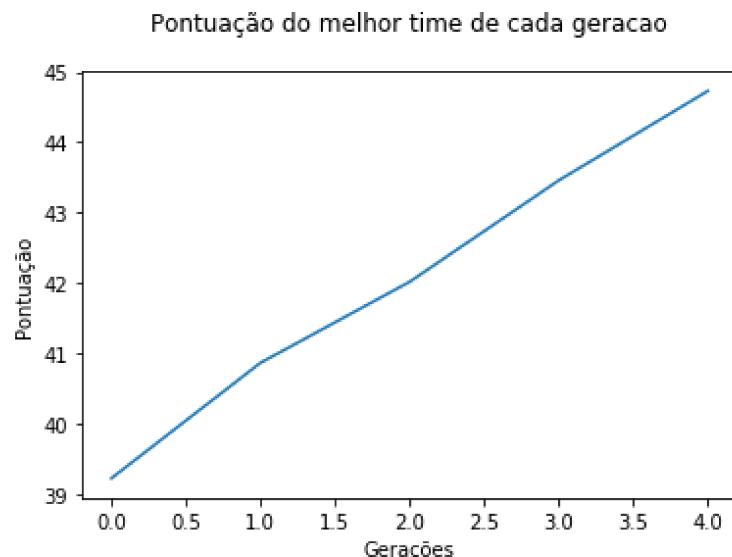


Figura 23 – Evolução da pontuação das melhores soluções

Para o esquema tático 5-3-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 10:

Tabela 10 – Time escalado no 5-3-2 para 6<sup>a</sup> rodada

Time
Jordi
Bruno
Igor Fernandes
Emerson Santos
Ernando
Gabriel
Jean Pyerre
Lucas Romero
Tchê Tchê
João Pedro
Rildo

O jogador escolhido como capitão foi João Pedro. Além disso, o preço do time é de 68.06, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 51.99 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 24 de evolução de pontuações das melhores soluções do algoritmo genético.

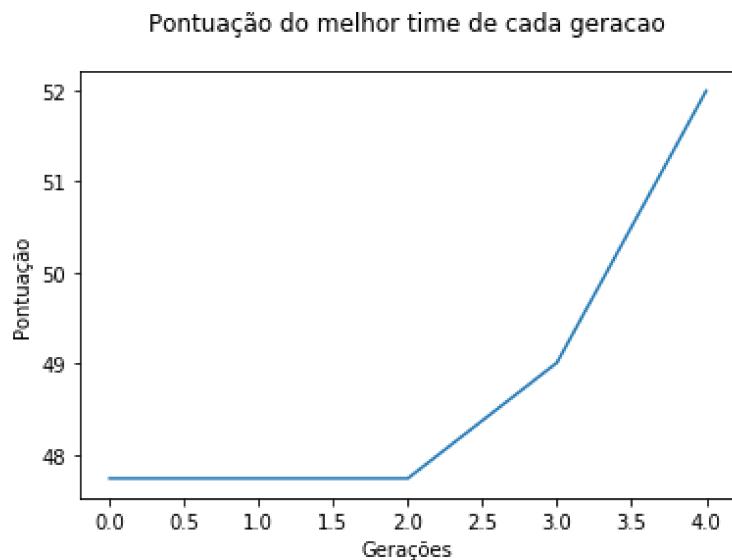


Figura 24 – Evolução da pontuação das melhores soluções

Para o esquema tático 3-4-3, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 11:

Tabela 11 – Time escalado no 3-4-3 para 6<sup>a</sup> rodada

Time
Fábio
Gerson
Walce
Yago
Andrey
Jean Pyerre
Romulo
Thiago Galhardo
João Pedro
Lourenço
Patrick Fabiano

O jogador escolhido como capitão foi Thiago Galhardo. Além disso, o preço do time é de 66.8, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 52.04 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 25 de evolução de pontuações das melhores soluções do algoritmo genético.

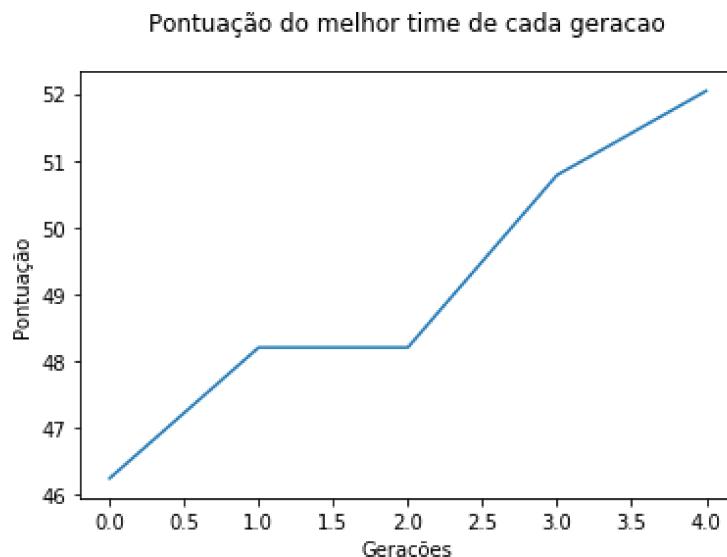


Figura 25 – Evolução da pontuação das melhores soluções

Para o esquema tático 3-5-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 12:

Tabela 12 – Time escalado no 3-5-2 para 6<sup>a</sup> rodada

Time
Vladimir
Emerson Santos
Gerson
Yago
Cazares
Geovane
Juninho
Márcio Araújo
Robinho
Caio Paulista
João Pedro

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 64.53, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 45.42 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 26 de evolução de pontuações das melhores soluções do algoritmo genético.

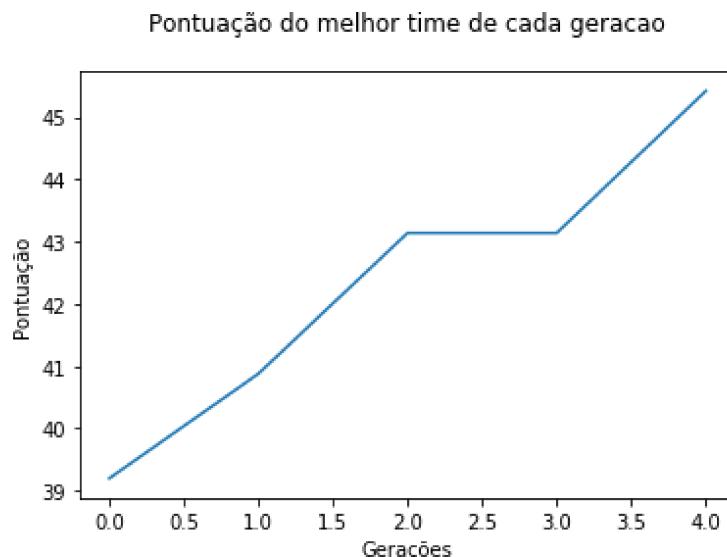


Figura 26 – Evolução da pontuação das melhores soluções

#### 4.1.1.1 Pontuação dos times

Na Figura 27, são mostradas as pontuações dos times escolhidos pelo algoritmo genético.

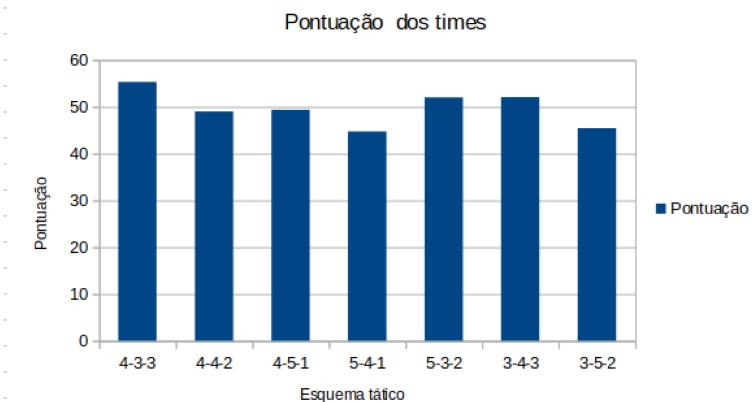


Figura 27 – Pontuação dos times

#### 4.1.2 Patrimônio de 100 cartoletas

Nesta subseção, serão apresentados os testes realizados com diferentes esquemas táticos para o limite de 100 cartoletas.

Para o esquema tático 4-3-3, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 13:

Tabela 13 – Time escalado no 4-3-3 para 6<sup>a</sup> rodada

Time
Fábio
Danilo Avelar
Fábio Santos
Gustavo Henrique
Valdo
Cazares
Léo Cittadini
Pedrinho
Lourenço
Marrony
Rony

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 93.89, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 56.50 pontos.

Esse time foi encontrado na geração inicial como pode ser mostrado pela Figura 28 de evolução de pontuações das melhores soluções do algoritmo genético.

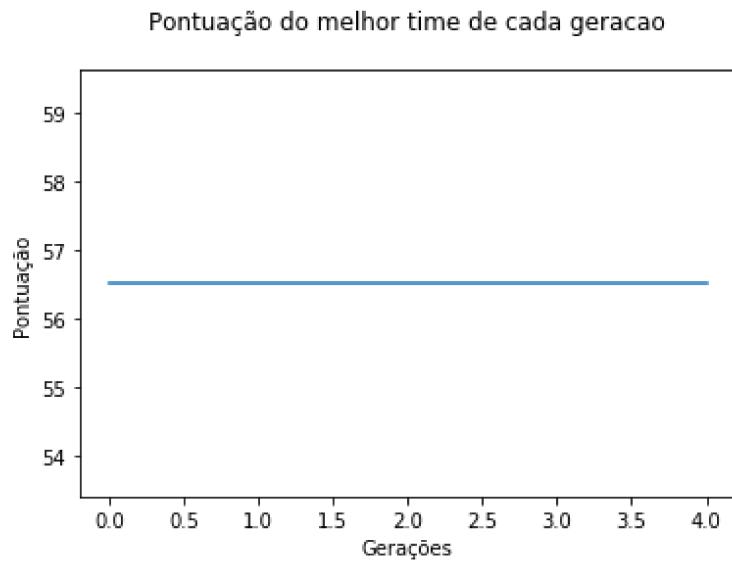


Figura 28 – Evolução da pontuação das melhores soluções

Para o esquema tático 4-4-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 14:

Tabela 14 – Time escalado no 4-4-2 para 6<sup>a</sup> rodada

Time
Fábio
Fagner
Renan Lodi
Gabriel
Yago
Carlos Sánchez
Cazares
Matheus Savio
Ricardinho
Michael
Rildo

O jogador escolhido como capitão foi Fágner. Além disso, o preço do time é de 96.63, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 55.94 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 29 de evolução de pontuações das melhores soluções do algoritmo genético.

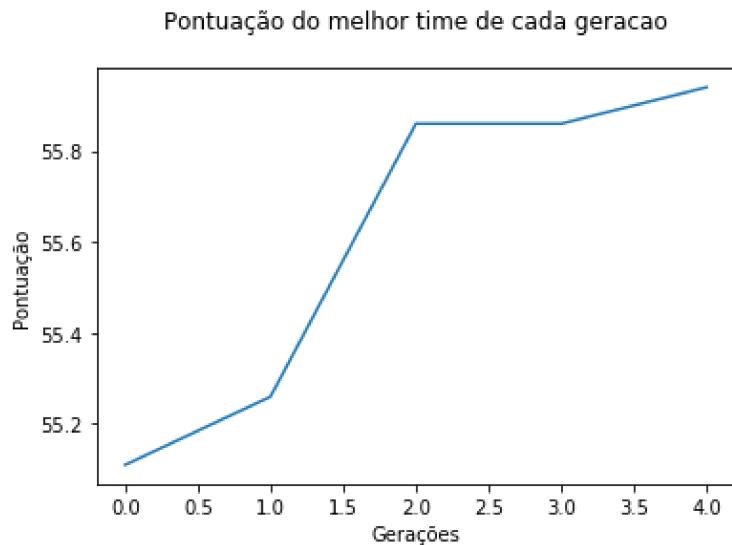


Figura 29 – Evolução da pontuação das melhores soluções

Para o esquema tático 4-5-1, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 15:

Tabela 15 – Time escalado no 4-5-1 para 6<sup>a</sup> rodada

Time
Fábio
Fagner
Nino Paraíba
Gabriel
Ricardo
Cazares
Cícero
Jean Pyerre
Matheus Barbosa
Thiago Galhardo
Alexandre Pato

O jogador escolhido como capitão foi Fágner. Além disso, o preço do time é de 96.75, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 56.39 pontos.

Esse time foi encontrado na geração inicial como pode ser mostrado pela Figura 30 de evolução de pontuações das melhores soluções do algoritmo genético.

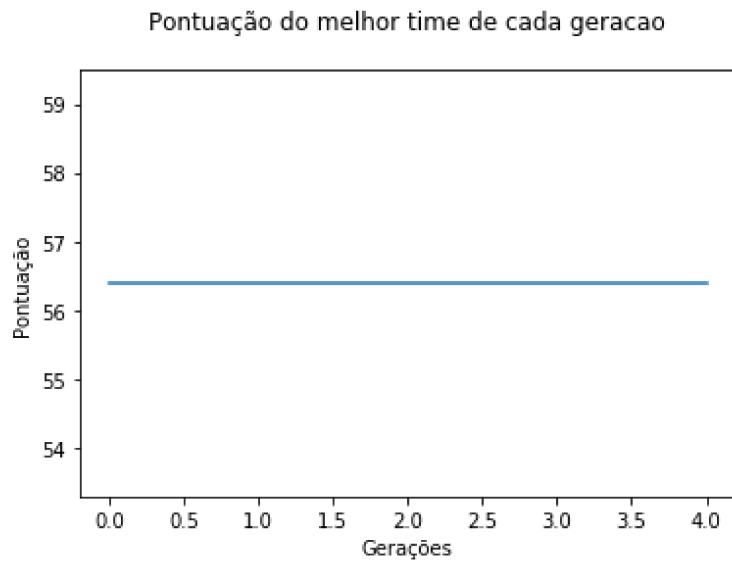


Figura 30 – Evolução da pontuação das melhores soluções

Para o esquema tático 5-4-1, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 16:

Tabela 16 – Time escalado no 5-4-1 para 6<sup>a</sup> rodada

Time
Tiago Volpi
Danilo Avelar
Madson
Dedé
Emerson Santos
Manoel
Alex Santana
Didira
Ralf
Thiago Galhardo
Rildo

O jogador escolhido como capitão foi Thiago Galhardo. Além disso, o preço do time é de 89.44, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 59.53 pontos.

Esse time foi encontrado na primeira geração como pode ser mostrado pela Figura 31 de evolução de pontuações das melhores soluções do algoritmo genético.

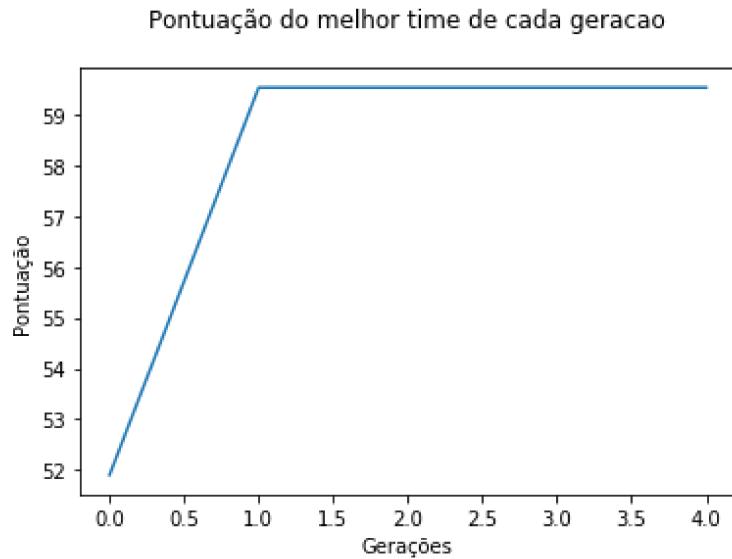


Figura 31 – Evolução da pontuação das melhores soluções

Para o esquema tático 5-3-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 17:

Tabela 17 – Time escalado no 5-3-2 para 6<sup>a</sup> rodada

Time
Fábio
Danilo Avelar
Egídio
Gabriel
Gustavo Henrique
Léo Duarte
Cazares
Rodriguinho
Thiago Galhardo
Artur
Marcinho

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 87.51, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 60.03 pontos.

Esse time foi encontrado na primeira geração como pode ser mostrado pela Figura 32 de evolução de pontuações das melhores soluções do algoritmo genético.

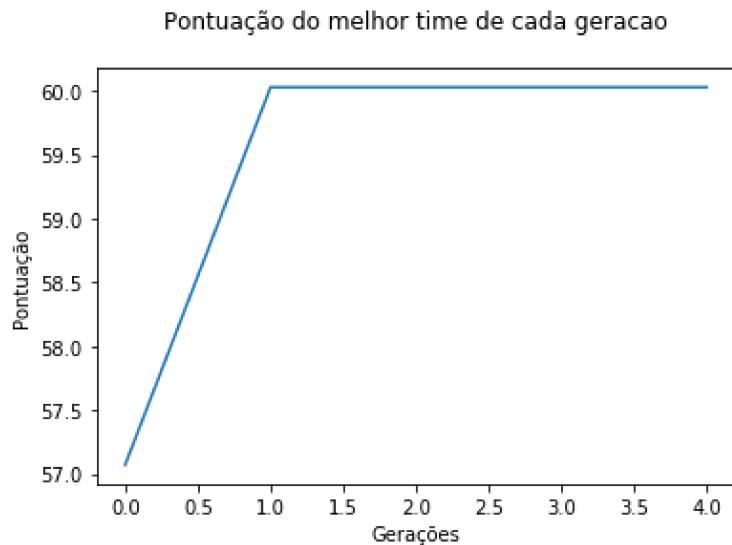


Figura 32 – Evolução da pontuação das melhores soluções

Para o esquema tático 3-4-3, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 18:

Tabela 18 – Time escalado no 3-4-3 para 6<sup>a</sup> rodada

Time
Cássio
Aguilar
Gum
Matheus Ferraz
Bruno César
Cazares
Jean Pyerre
Thiago Galhardo
Artur
Everaldo
João Pedro

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 93.62, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 61.51 pontos.

Esse time foi encontrado na segunda geração como pode ser mostrado pela Figura 33 de evolução de pontuações das melhores soluções do algoritmo genético.

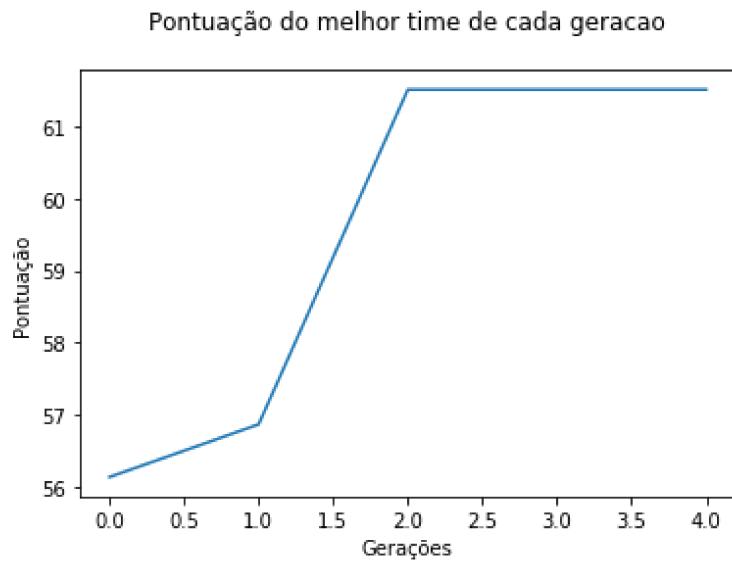


Figura 33 – Evolução da pontuação das melhores soluções

Para o esquema tático 3-5-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 19:

Tabela 19 – Time escalado no 3-5-2 para 6<sup>a</sup> rodada

Time
Fábio
Dedé
Gustavo Henrique
Léo Pereira
Caio Henrique
Carlos Sánchez
Cazares
Fernando Sobral
Thiago Galhardo
João Pedro
Rildo

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 96.25, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 60.34 pontos.

Esse time foi encontrado na geração inicial como pode ser mostrado pela Figura 34 de evolução de pontuações das melhores soluções do algoritmo genético.

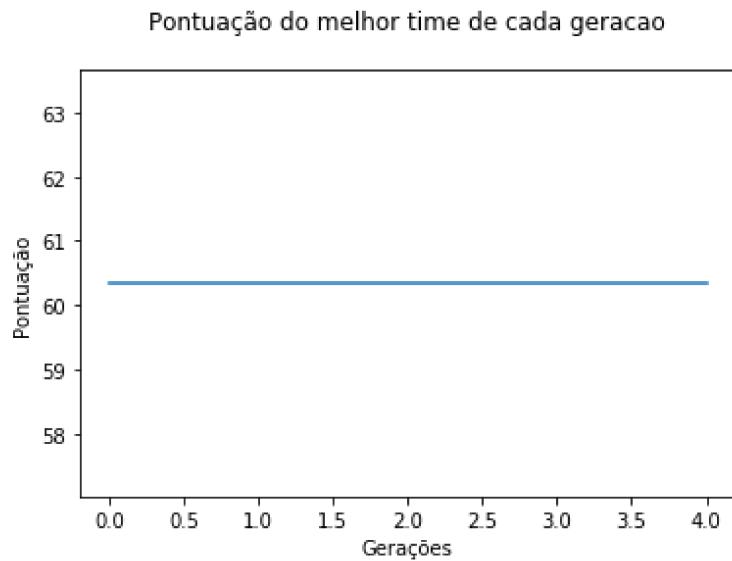


Figura 34 – Evolução da pontuação das melhores soluções

#### 4.1.3 Pontuação dos times

Na Figura 35, serão mostradas as pontuações dos times gerados pelo algoritmo genético.

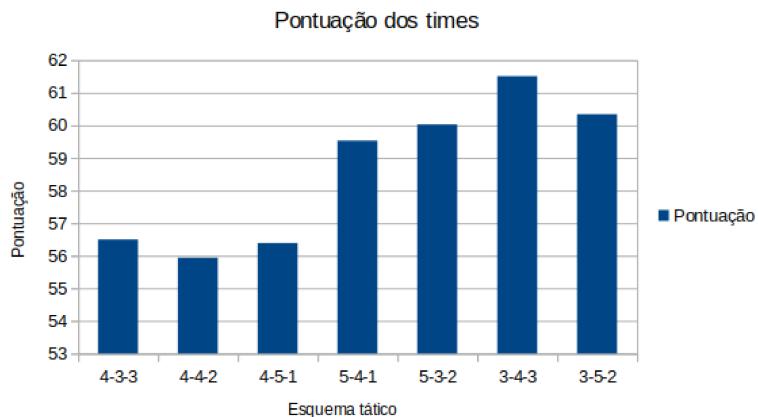


Figura 35 – Pontuação dos times

#### 4.1.4 Patrimônio de 150 cartoletas

Nessa subseção serão apresentados os testes realizados com diferentes esquemas táticos para o limite de 150 cartoletas.

Para o esquema tático 4-3-3, a execução do algoritmo genético retornou o seguinte time, conforme a tabela 20:

Tabela 20 – Time escalado no 4-3-3 para 6<sup>a</sup> rodada

Time
Marcelo Lomba
Daniel Guedes
Fagner
Gerson
Walce
Cuéllar
Robinho
Thiago Galhardo
Rildo
Rony
Yony González

O jogador escolhido como capitão foi Fágner. Além disso, o preço do time é de 103.28, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 64.22 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 36 de evolução de pontuações das melhores soluções do algoritmo genético.

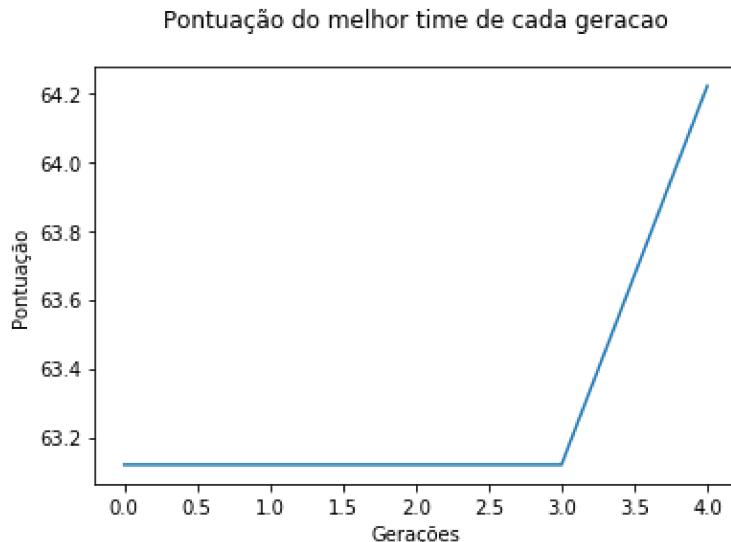


Figura 36 – Evolução da pontuação das melhores soluções

Para o esquema tático 4-4-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 21:

Tabela 21 – Time escalado no 4-4-2 para 6<sup>a</sup> rodada

Time
Vanderlei
Edílson
Fagner
Manoel
Matheus Ferraz
Alex Santana
Nonato
Pedro Castro
Rodrigo Lindoso
Everton
Rildo

O jogador escolhido como capitão foi Fágner. Além disso, o preço do time é de 113.83, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 62.59 pontos.

Esse time foi encontrado na geração inicial como pode ser mostrado pela Figura 37 de evolução de pontuações das melhores soluções do algoritmo genético.

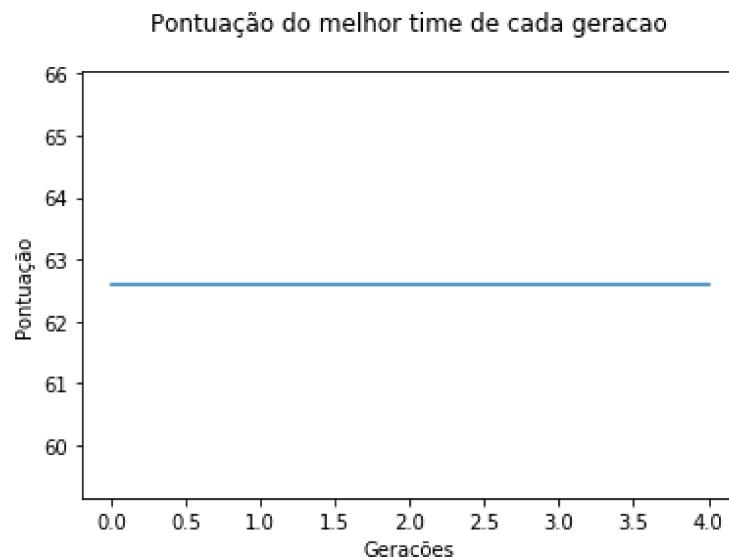


Figura 37 – Evolução da pontuação das melhores soluções

Para o esquema tático 4-5-1, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 22:

Tabela 22 – Time escalado no 4-5-1 para 6<sup>a</sup> rodada

Time
Fábio
Bruno Pacheco
Juninho Capixaba
Arboleda
Matheus Ferraz
Jean Pyerre
Lucas Mineiro
Márcio Araújo
Nonato
Thiago Galhardo
Everton

O jogador escolhido como capitão foi Thiago Galhardo. Além disso, o preço do time é de 106.69, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 63.16 pontos.

Esse time foi encontrado na segunda geração como pode ser mostrado pela Figura 38 de evolução de pontuações das melhores soluções do algoritmo genético.

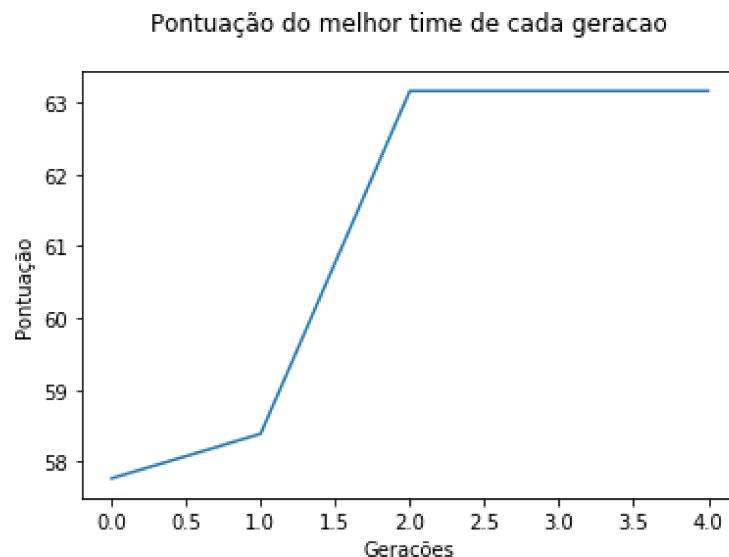


Figura 38 – Evolução da pontuação das melhores soluções

Para o esquema tático 5-4-1, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 23:

Tabela 23 – Time escalado no 5-4-1 para 6<sup>a</sup> rodada

Time
Douglas Friedrich
Samuel Xavier
Victor Ferraz
Léo Pereira
Marquinhos Silva
Pedro Geromel
Alex Santana
Cuéllar
Cícero
Jean Pyerre
Bruno Henrique

O jogador escolhido como capitão foi Cuéllar. Além disso, o preço do time é de 125.41, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 60.83 pontos.

Esse time foi encontrado na terceira geração como pode ser mostrado pela Figura 39 de evolução de pontuações das melhores soluções do algoritmo genético.

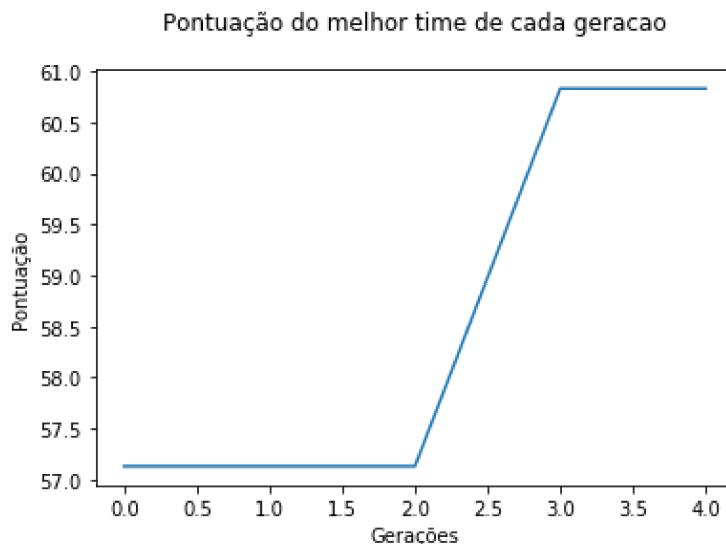


Figura 39 – Evolução da pontuação das melhores soluções

Para o esquema tático 5-3-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 24:

Tabela 24 – Time escalado no 5-3-2 para 6<sup>a</sup> rodada

Time
Fábio
Fagner
Juninho Capixaba
Arboleda
Dedé
Igor Rabello
Cuéllar
Cícero
Thiago Galhardo
Everaldo
Geuvânio

O jogador escolhido como capitão foi Fagner. Além disso, o preço do time é de 127.22, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 63 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 40 de evolução de pontuações das melhores soluções do algoritmo genético.

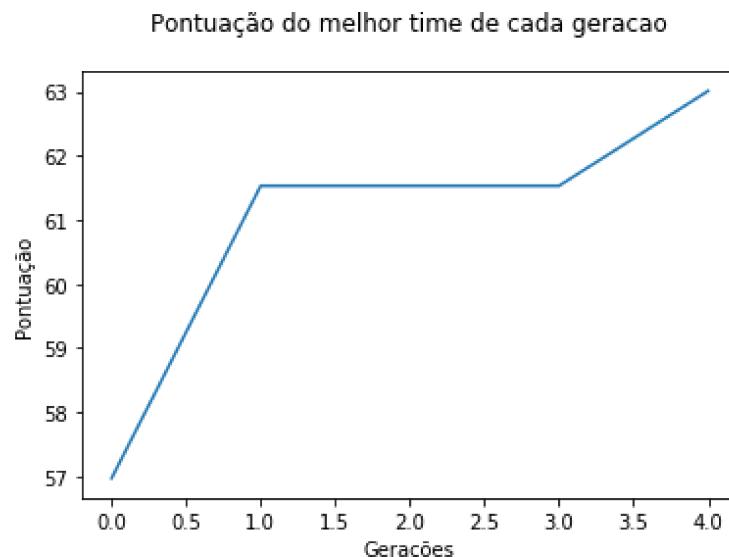


Figura 40 – Evolução da pontuação das melhores soluções

Para o esquema tático 3-4-3, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 25:

Tabela 25 – Time escalado no 3-4-3 para 6<sup>a</sup> rodada

Time
Tadeu
Dedé
Matheus Ferraz
Pedro Geromel
Alisson
Cazares
Tchê Tchê
Thiago Galhardo
Everaldo
Geuvânio
Lourenço

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 111.29, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 62.96 pontos.

Esse time foi encontrado na segunda geração como pode ser mostrado pela Figura 41 de evolução de pontuações das melhores soluções do algoritmo genético.

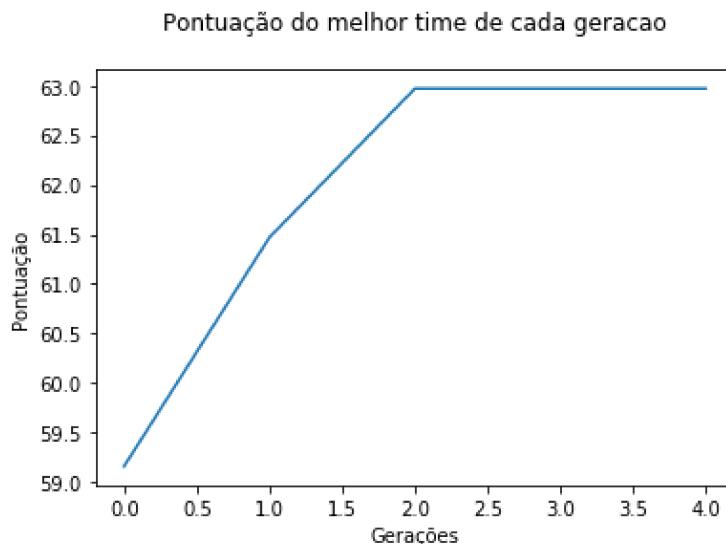


Figura 41 – Evolução da pontuação das melhores soluções

Para o esquema tático 3-5-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 26:

Tabela 26 – Time escalado no 3-5-2 para 6<sup>a</sup> rodada

Time
Douglas Friedrich
David Duarte
Dedé
Léo Duarte
Márcio Araújo
Ricardinho
Robinho
Rodrigo Lindoso
Thiago Galhardo
João Pedro
Rildo

O jogador escolhido como capitão foi Thiago Galhardo. Além disso, o preço do time é de 93.99, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 61.56 pontos.

Esse time foi encontrado na terceira geração como pode ser mostrado pela Figura 42 de evolução de pontuações das melhores soluções do algoritmo genético.

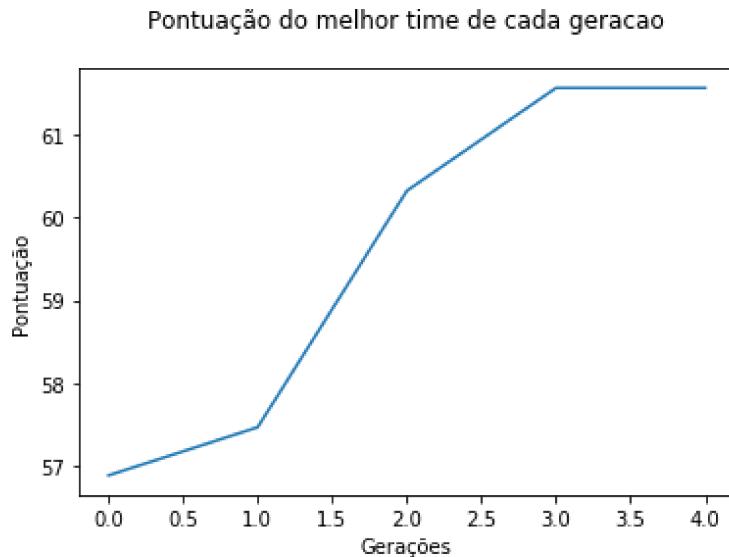


Figura 42 – Evolução da pontuação das melhores soluções

#### 4.1.5 Pontuação dos times

Na Figura 43, serão mostradas as pontuações dos times gerados pelo algoritmo genético.

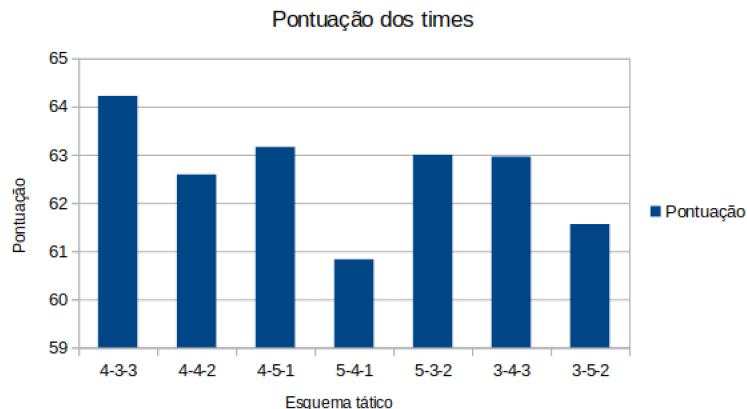


Figura 43 – Pontuação dos times

## 4.2 Rodada 7

Nesta seção, serão apresentados os testes realizados na 7<sup>a</sup> rodada com os limites de patrimônios mencionados, variando os esquemas táticos.

### 4.2.1 Patrimônio de 70 cartoletas

Nesta subseção, serão apresentados os testes realizados com diferentes esquemas táticos para o limite de 70 cartoletas.

Para o esquema tático 4-3-3, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 27:

Tabela 27 – Time escalado no 4-3-3 para 7<sup>a</sup> rodada

Time
Diogo Silva
Fernando
Igor Fernandes
Emerson Santos
Matheus Ferraz
Jean Pyerre
Matheus Barbosa
Ronaldo
Erik
João Pedro
Rildo

O jogador escolhido como capitão foi João Pedro. Além disso, o preço do time é de 66.08, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 50.17 pontos.

Esse time foi encontrado na terceira geração como pode ser mostrado pela Figura 44 de evolução de pontuações das melhores soluções do algoritmo genético.

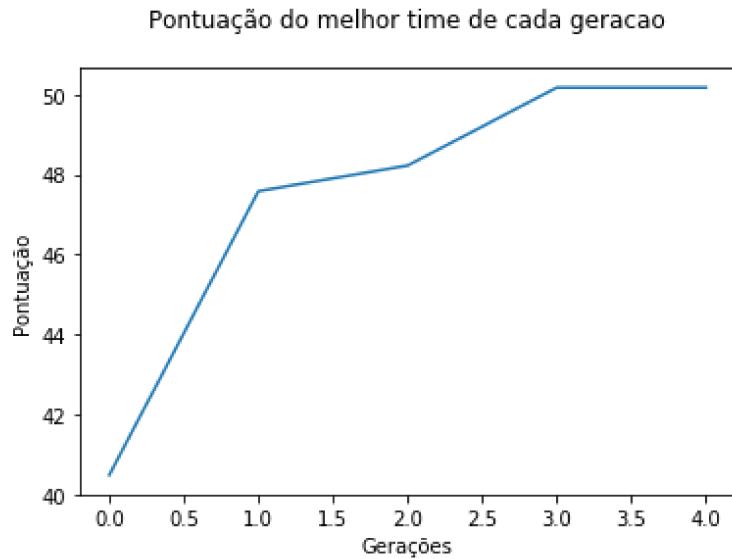


Figura 44 – Evolução da pontuação das melhores soluções

Para o esquema tático 4-4-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 28:

Tabela 28 – Time escalado no 4-4-2 para 7<sup>a</sup> rodada

Time
Jordi
Igor Fernandes
Moisés
Betão
Valdo
Gabriel Dias
Márcio Araújo
Rodriguinho
Thiago Galhardo
João Pedro
Luciano

O jogador escolhido como capitão foi Thiago Galhardo. Além disso, o preço do time é de 67.83, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 50.17 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 45 de evolução de pontuações das melhores soluções do algoritmo genético.

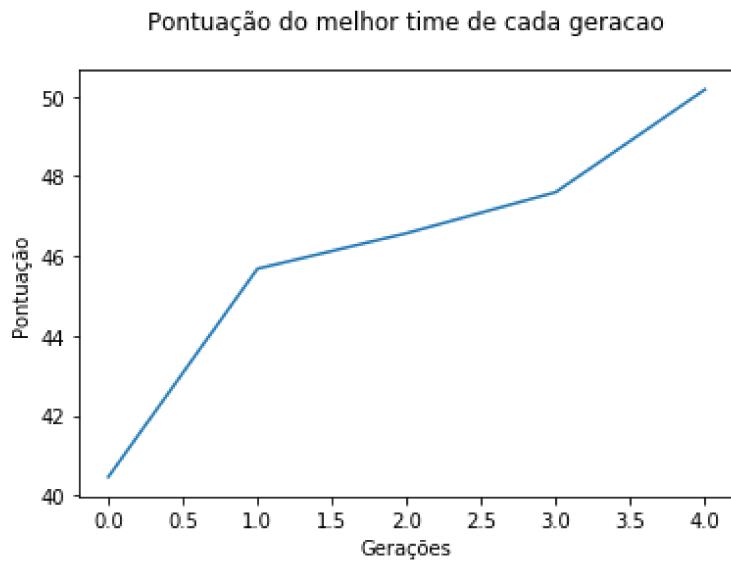


Figura 45 – Evolução da pontuação das melhores soluções

Para o esquema tático 4-5-1, a execução do algoritmo genético retornou o seguinte timec, conforme a Tabela 29:

Tabela 29 – Time escalado no 4-5-1 para 7<sup>a</sup> rodada

Time
Jordi
Fernando
Igor Fernandes
Betão
Nino
Cícero
Lucho González
Márcio Araújo
Nonato
Rodrigo Lindoso
Lourenço

O jogador escolhido como capitão foi Nonato. Além disso, o preço do time é de 69.29, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 48.59 pontos.

Esse time foi encontrado na geração inicial como pode ser mostrado pela Figura 46 de evolução de pontuações das melhores soluções do algoritmo genético.

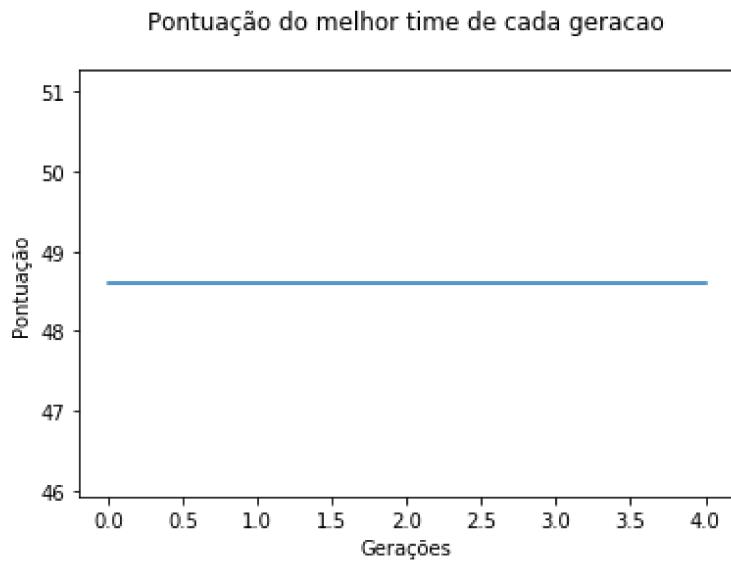


Figura 46 – Evolução da pontuação das melhores soluções

Para o 5-4-1, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 30:

Tabela 30 – Time escalado no 5-4-1 para 7<sup>a</sup> rodada

Jordi
Igor Fernandes
Juninho Capixaba
Betão
Luciano Castán
Matheus Ferraz
Elias
Matheus Barbosa
Nonato
Ronaldo
João Pedro

O jogador escolhido como capitão foi João Pedro. Além disso, o preço do time é de 63.3, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 46.02 pontos.

Esse time foi encontrado na terceira geração como pode ser mostrado pela Figura 47 de evolução de pontuações das melhores soluções do algoritmo genético.

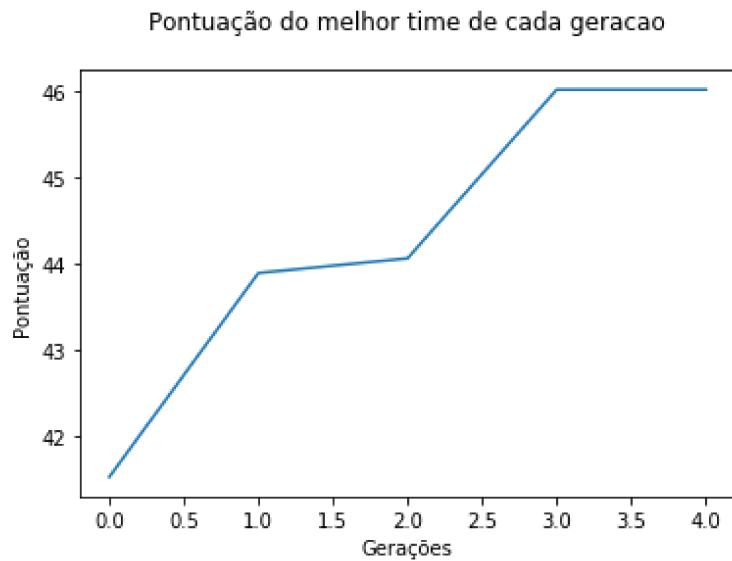


Figura 47 – Evolução da pontuação das melhores soluções

Para o esquema tático 5-3-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 31:

Tabela 31 – Time escalado no 5-3-2 para 7<sup>a</sup> rodada

Time
Paulo Victor
Fernando
Juninho Capixaba
Betão
Joel Carli
Pedro Geromel
Elicarlos
Gustavo Campanharo
Jean Pyerre
João Pedro
Lourenço

O jogador escolhido como capitão foi João Pedro. Além disso, o preço do time é de 62.40, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 46.65 pontos.

Esse time foi encontrado na primeira geração como pode ser mostrado pela Figura 48 de evolução de pontuações das melhores soluções do algoritmo genético.

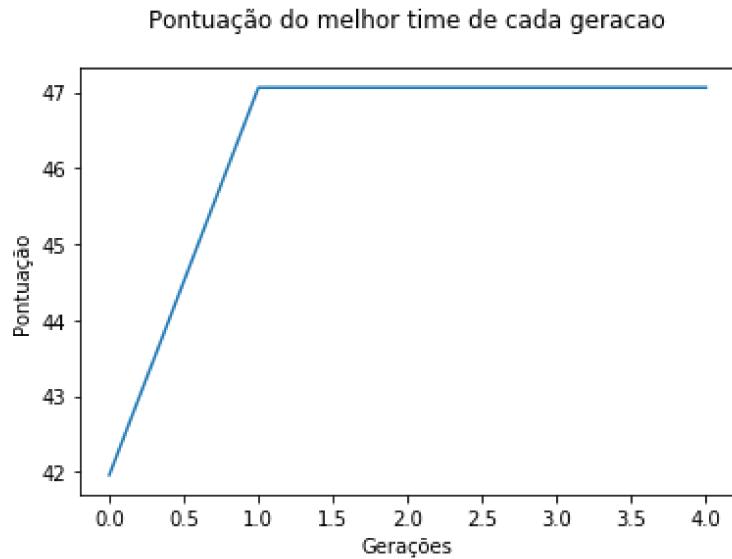


Figura 48 – Evolução da pontuação das melhores soluções

Para o esquema tático 3-4-3, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 32:

Tabela 32 – Time escalado no 3-4-3 para 7<sup>a</sup> rodada

Vladimir
Emerson Santos
Gabriel
Gum
Henrique
João Paulo
Ronaldo
Thiago Neves
Berrío
Romarinho
Vitinho

O jogador escolhido como capitão foi Vitinho. Além disso, o preço do time é de 69.96, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 43.69 pontos.

Esse time foi encontrado na segunda geração como pode ser mostrado pela Figura 49 de evolução de pontuações das melhores soluções do algoritmo genético.

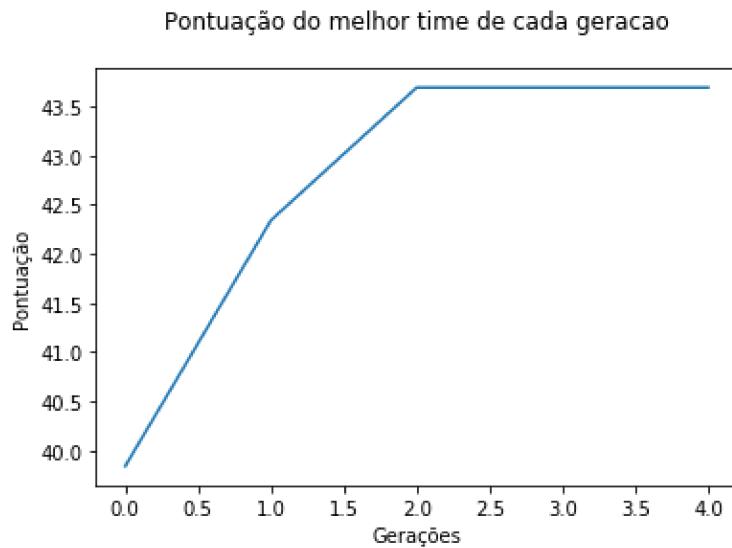


Figura 49 – Evolução da pontuação das melhores soluções

Para o esquema tático 3-5-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 33:

Tabela 33 – Time escalado no 3-5-2 para 7<sup>a</sup> rodada

Time
Douglas Friedrich
Betão
Gum
Nino
Andrey
Lucas Mineiro
Naldo
Rodrigo Lindoso
Thiago Galhardo
Berrío
João Pedro

O jogador escolhido como capitão foi Thiago Galhardo. Além disso, o preço do time é de 67.04, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 48.17 pontos.

Esse time foi encontrado na terceira geração como pode ser mostrado pela Figura 50 de evolução de pontuações das melhores soluções do algoritmo genético.

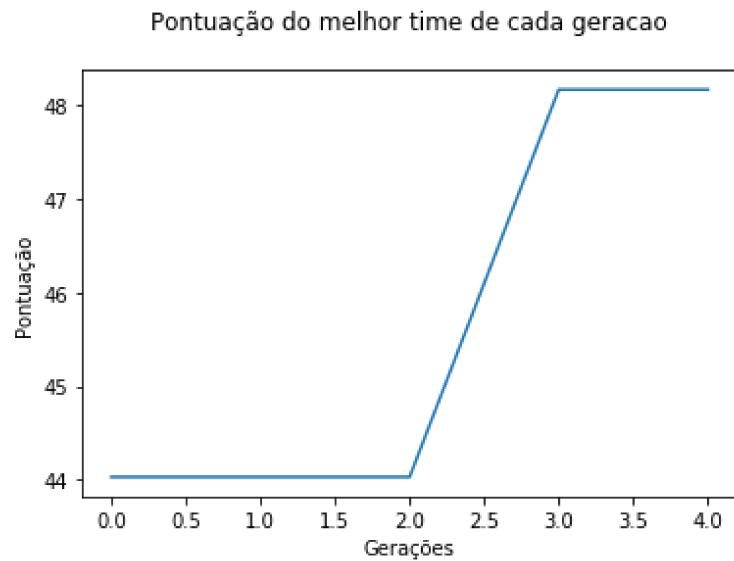


Figura 50 – Evolução da pontuação das melhores soluções

#### 4.2.2 Pontuação dos times

Na Figura 51, serão mostradas as pontuações dos times gerados pelo algoritmo genético.

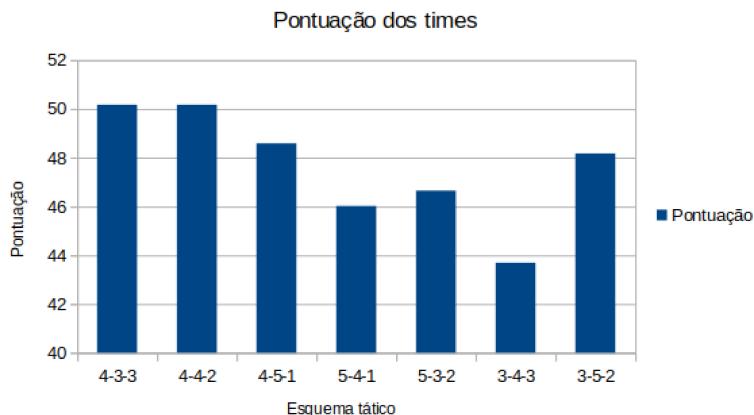


Figura 51 – Pontuação dos times

#### 4.2.3 Patrimônio de 100 cartoletas

Nesta subseção, serão apresentados os testes realizados com diferentes esquemas táticos para o limite de 100 cartoletas.

Para o esquema tático 4-3-3, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 34:

Tabela 34 – Time escalado no 4-3-3 para 7<sup>a</sup> rodada

Time
Jordi
Egídio
Leonardo
Dedé
Léo Pereira
Cazares
Matheus Barbosa
Tchê Tchê
Marcinho
Rony
Vitinho

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 97.21, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 58.38 pontos.

Esse time foi encontrado na geração inicial como pode ser mostrado pela Figura 52 de evolução de pontuações das melhores soluções do algoritmo genético.

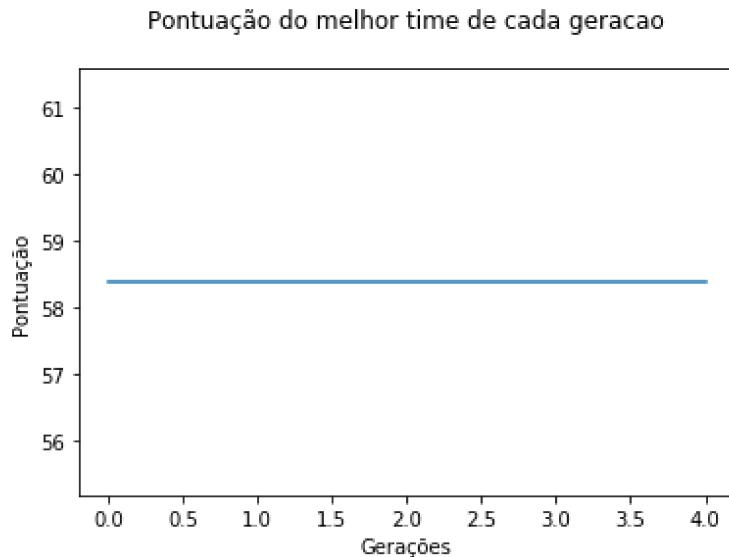


Figura 52 – Evolução da pontuação das melhores soluções

Para o esquema tático 4-4-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 35:

Tabela 35 – Time escalado no 4-4-2 para 7<sup>a</sup> rodada

Time
Paulo Victor
Bruno Pacheco
Fernando
Betão
Léo Pereira
Arrascaeta
Cazares
Cuéllar
Gustavo Campanharo
João Pedro
Vitinho

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 86.97, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 56.89 pontos.

Esse time foi encontrado na terceira geração como pode ser mostrado pela Figura 53 de evolução de pontuações das melhores soluções do algoritmo genético.

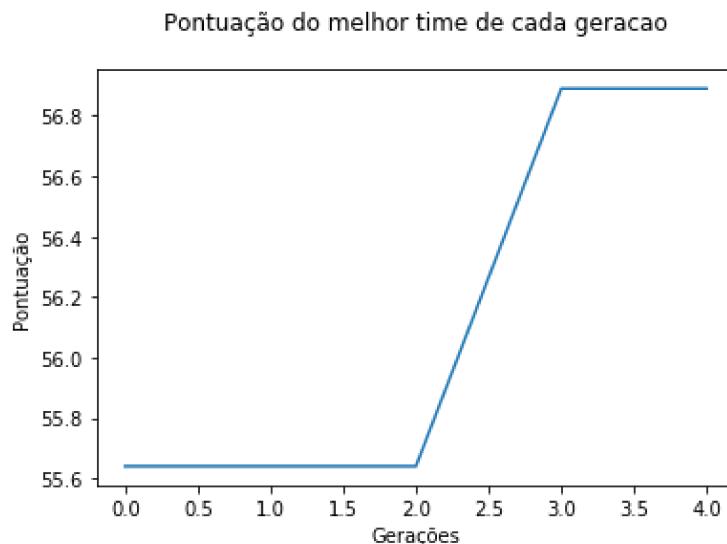


Figura 53 – Evolução da pontuação das melhores soluções

Para o esquema tático 4-5-1, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 36:

Tabela 36 – Time escalado no 4-5-1 para 7<sup>a</sup> rodada

Time
Douglas Friedrich
Fábio Santos
Reinaldo
Gabriel
Léo Pereira
Everton
Jean Pyerre
José Welison
Juninho
Thiago Galhardo
Rildo

O jogador escolhido como capitão foi Thiago Galhardo. Além disso, o preço do time é de 95.50, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 56.53 pontos.

Esse time foi encontrado na segunda geração como pode ser mostrado pela Figura 54 de evolução de pontuações das melhores soluções do algoritmo genético.

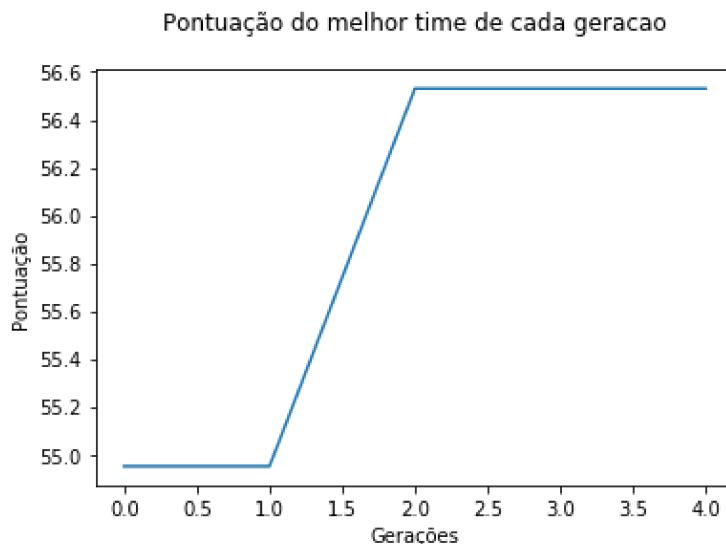


Figura 54 – Evolução da pontuação das melhores soluções

Para o esquema tático 5-4-1, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 37:

Tabela 37 – Time escalado no 5-4-1 para 7<sup>a</sup> rodada

Time
Jordi
Carlinhos
Fernando
Emerson Santos
Joel Carli
Pedro Geromel
Cazares
Matheus Savio
Nikão
Rodrigo Lindoso
Rony

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 99.94, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 57.72 pontos.

Esse time foi encontrado na terceira geração como pode ser mostrado pela Figura 55 de evolução de pontuações das melhores soluções do algoritmo genético.

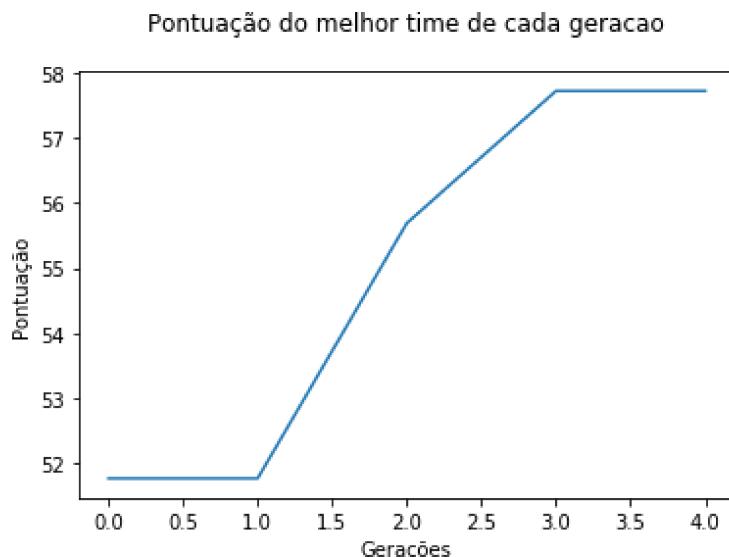


Figura 55 – Evolução da pontuação das melhores soluções

Para o esquema tático 5-3-2, a execução do algoritmo genético retornou o seguinte time, conforme Tabela 38:

Tabela 38 – Time escalado no 5-3-2 para 7<sup>a</sup> rodada

Time
Felipe Alves
Igor Fernandes
Moisés
Betão
Pedro Geromel
Ricardo
Nikão
Nonato
Thiago Galhardo
Rildo
Yony González

O jogador escolhido como capitão foi Thiago Galhardo. Além disso, o preço do time é de 99.23, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 58.60 pontos.

Esse time foi encontrado na geração inicial como pode ser mostrado pela Figura 56 de evolução de pontuações das melhores soluções do algoritmo genético.

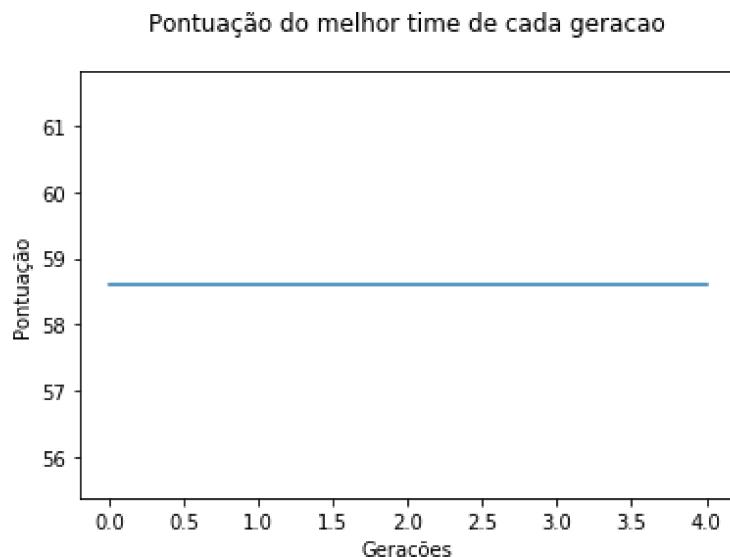


Figura 56 – Evolução da pontuação das melhores soluções

Para o esquema tático 3-4-3, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 39:

Tabela 39 – Time escalado no 3-4-3 para 7<sup>a</sup> rodada

Time
Vladimir
Bruno Alves
Ernando
Lucas Veríssimo
Andrey
Bruno Guimarães
Jean Pyerre
Thiago Galhardo
Marcinho
Romarinho
Vitinho

O jogador escolhido como capitão foi Thiago Galhardo. Além disso, o preço do time é de 89.60, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 56.92 pontos.

Esse time foi encontrado na terceira geração como pode ser mostrado pela Figura 57 de evolução de pontuações das melhores soluções do algoritmo genético.

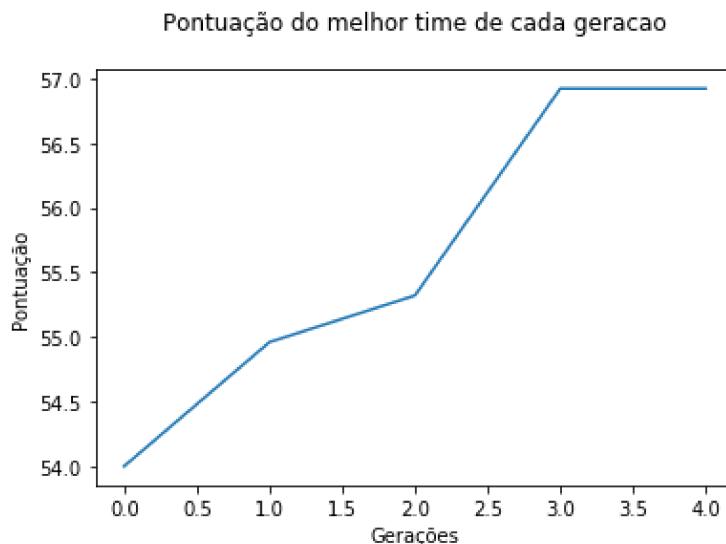


Figura 57 – Evolução da pontuação das melhores soluções

Para o esquema tático 3-5-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 40:

Tabela 40 – Time escalado no 3-5-2 para 7<sup>a</sup> rodada

Time
Vanderlei
Lucas Fonseca
Lucas Veríssimo
Nino
Cazares
Everton
Gegê
Nonato
Thiago Galhardo
João Pedro
Leandro Carvalho

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 93.46, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 57.28 pontos.

Esse time foi encontrado na segunda geração como pode ser mostrado pela Figura 58 de evolução de pontuações das melhores soluções do algoritmo genético.

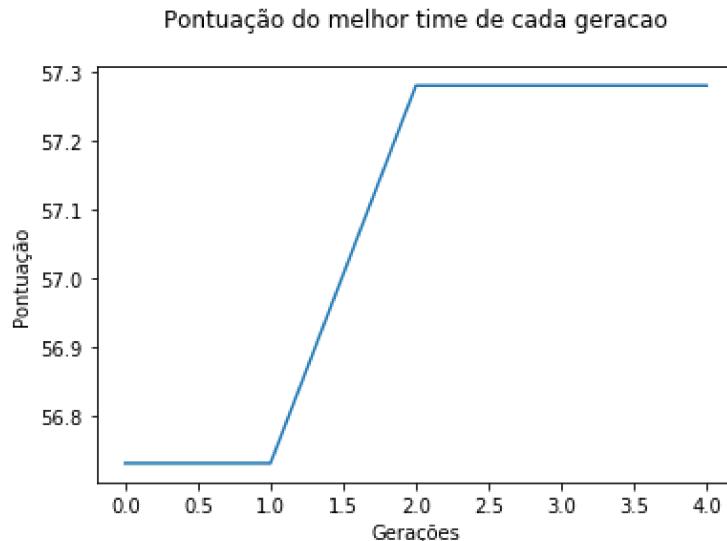


Figura 58 – Evolução da pontuação das melhores soluções

#### 4.2.4 Pontuação dos times

Na Figura 59, serão mostradas as pontuações dos times gerados pelo algoritmo genético.

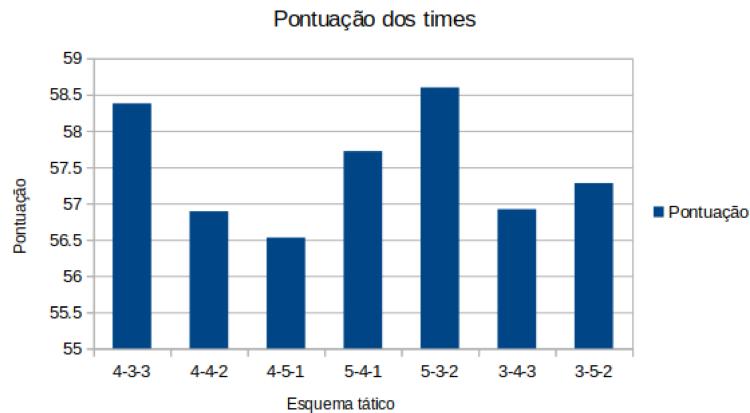


Figura 59 – Pontuação dos times

#### 4.2.5 Patrimônio de 150 cartoletas

Nesta subseção, serão apresentados os testes realizados com diferentes esquemas táticos para o limite de 150 cartoletas.

Para o esquema tático 4-3-3, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 41:

Tabela 41 – Time escalado no 4-3-3 para 7<sup>a</sup> rodada

Time
Vladimir
Bruno Pacheco
Fábio Santos
Betão
Dedé
Cazares
Nikão
Thiago Galhardo
Arthur Caíke
Rildo
Rony

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 119.02, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 64.37 pontos.

Esse time foi encontrado na segunda geração como pode ser mostrado pela Figura 60 de evolução de pontuações das melhores soluções do algoritmo genético.

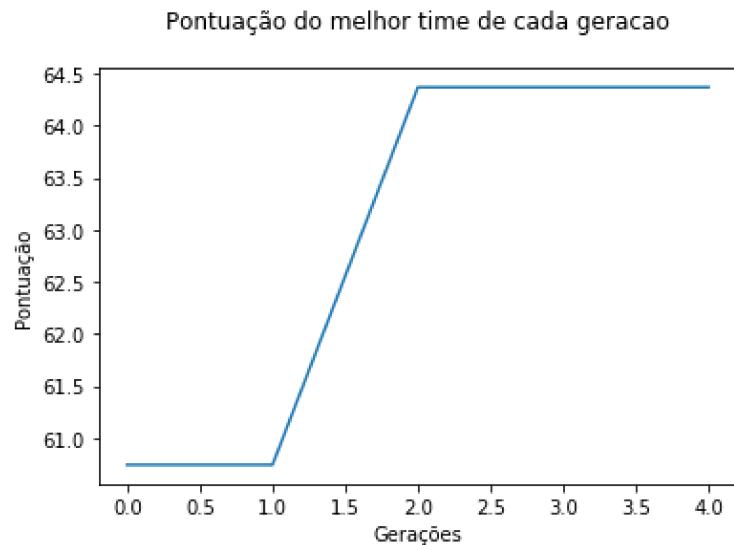


Figura 60 – Evolução da pontuação das melhores soluções

Para o esquema tático 4-4-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 42:

Tabela 42 – Time escalado no 4-4-2 para 7<sup>a</sup> rodada

Time
Vanderlei
Bruno Pacheco
Carlinhos
Betão
Ernando
Cazares
Maicon
Robinho
Thiago Galhardo
João Pedro
Marco Ruben

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 112.84, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 63.48 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 61 de evolução de pontuações das melhores soluções do algoritmo genético.

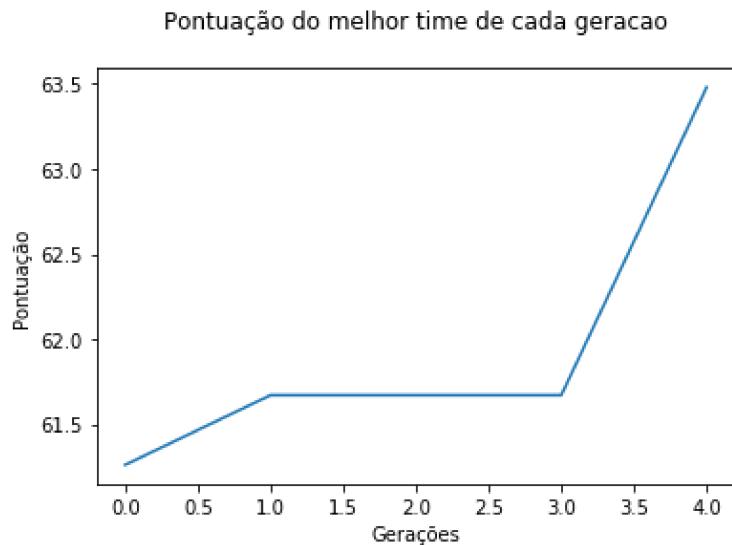


Figura 61 – Evolução da pontuação das melhores soluções

Para o esquema tático 4-5-1, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 43:

Tabela 43 – Time escalado no 4-5-1 para 7<sup>a</sup> rodada

Time
Tiepo
Juninho Capixaba
Moisés
Arboleda
Léo Pereira
Cazares
Cuéllar
Ricardinho
Robinho
Rodrigo Lindoso
Ricardo Oliveira

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 119.06, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 61.72 pontos.

Esse time foi encontrado na geração inicial como pode ser mostrado pela Figura 62 de evolução de pontuações das melhores soluções do algoritmo genético.

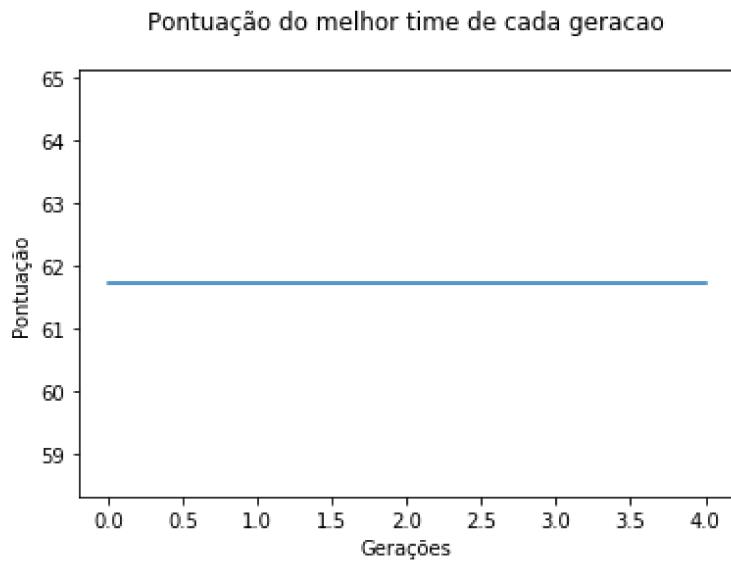


Figura 62 – Evolução da pontuação das melhores soluções

Para o esquema tático 5-4-1, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 44:

Tabela 44 – Time escalado no 5-4-1 para 7<sup>a</sup> rodada

Time
Douglas Friedrich
Egídio
Gilson
Dedé
Pedro Geromel
Valdo
Alex Santana
Gabriel Dias
Luan
Nikão
Vitinho

O jogador escolhido como capitão foi Vitinho. Além disso, o preço do time é de 103.72, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 57.99 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 63 de evolução de pontuações das melhores soluções do algoritmo genético.

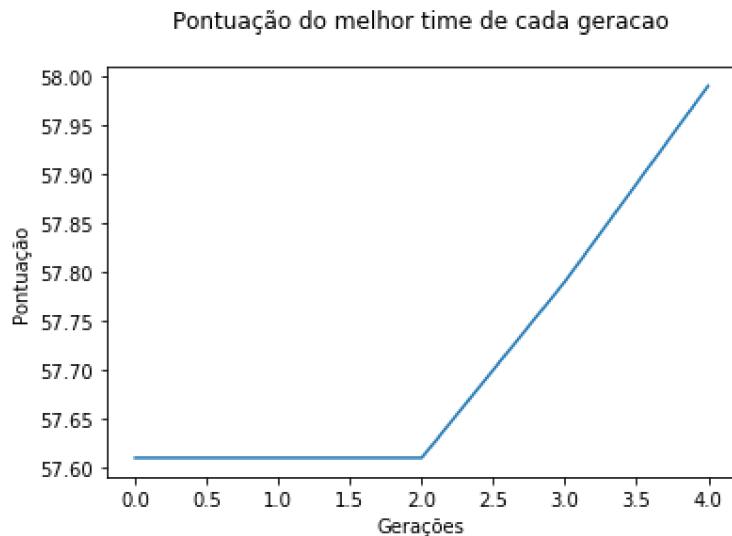


Figura 63 – Evolução da pontuação das melhores soluções

Para o esquema tático 5-3-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 45:

Tabela 45 – Time escalado no 5-3-2 para 7<sup>a</sup> rodada

Time
Tiepo
Egídio
Moisés
Gum
Pedro Geromel
Roger Carvalho
Cazares
João Paulo
Thiago Galhardo
Marcinho
Paolo Guerrero

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 107.56, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 61.06 pontos.

Esse time foi encontrado na terceira geração como pode ser mostrado pela Figura 64 de evolução de pontuações das melhores soluções do algoritmo genético.

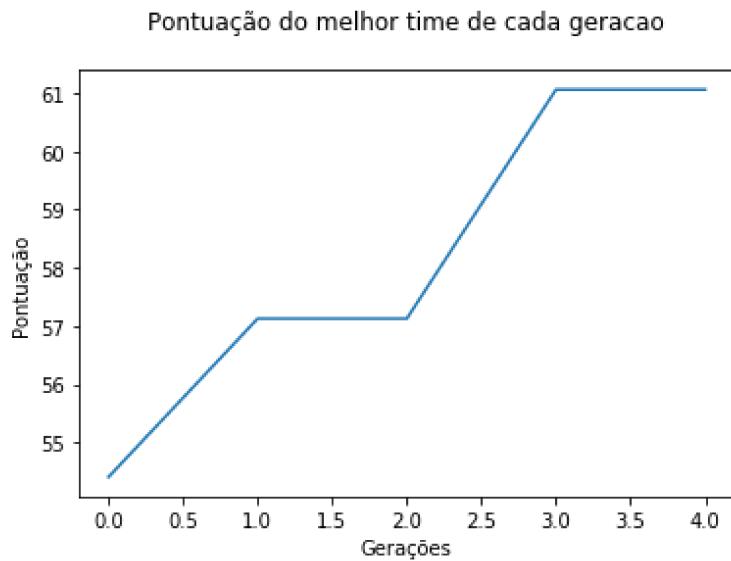


Figura 64 – Evolução da pontuação das melhores soluções

Para o esquema tático 3-4-3, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 46:

Tabela 46 – Time escalado no 3-4-3 para 7<sup>a</sup> rodada

Time
Vanderlei
Lucas Fonseca
Léo Pereira
Víctor Cuesta
Alex Santana
Bruno Guimarães
Cazares
José Welison
Berrío
Rildo
Yony González

O jogador escolhido como capitão foi Cazares. Além disso, o preço do time é de 114.72, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 63.54 pontos.

Esse time foi encontrado na quarta geração como pode ser mostrado pela Figura 65 de evolução de pontuações das melhores soluções do algoritmo genético.

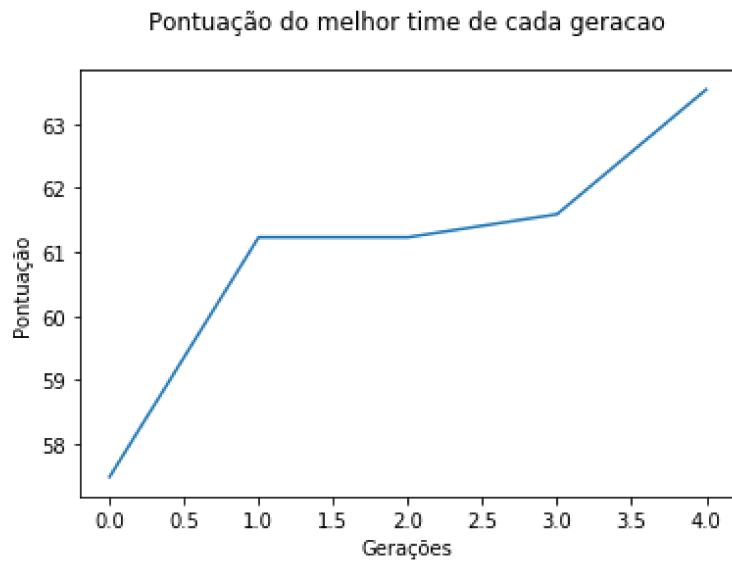


Figura 65 – Evolução da pontuação das melhores soluções

Para o esquema tático 3-5-2, a execução do algoritmo genético retornou o seguinte time, conforme a Tabela 47:

Tabela 47 – Time escalado no 3-5-2 para 7<sup>a</sup> rodada

Time
Vanderlei
Betão
Gerson
Víctor Cuesta
Bruno Guimarães
Lucho González
Nikão
Nonato
Thiago Galhardo
Marcinho
Marco Ruben

O jogador escolhido como capitão foi Thiago Galhardo. Além disso, o preço do time é de 125.86, respeitando o limite de patrimônio. Outra informação relevante é a pontuação predita do time que foi de 63.30 pontos.

Esse time foi encontrado na terceira geração como pode ser mostrado pela Figura 66 de evolução de pontuações das melhores soluções do algoritmo genético.

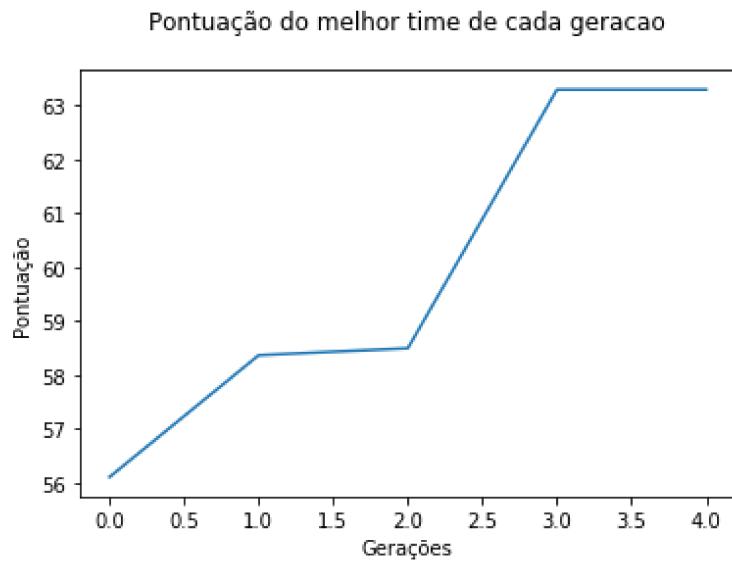


Figura 66 – Evolução da pontuação das melhores soluções

#### 4.2.6 Pontuação dos times

Na Figura 67, serão mostradas as pontuações dos times gerados pelo algoritmo genético.

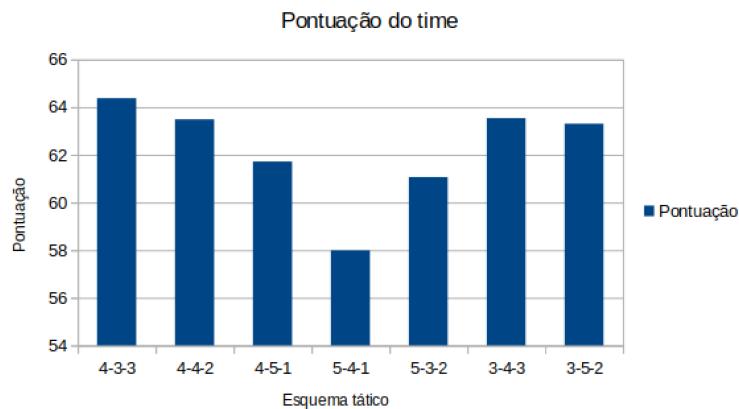


Figura 67 – Pontuação dos times

### 4.3 Comparação da pontuação média entre diferentes limites de patrimônio por rodada

Após a realização de testes com o algoritmo genético para as rodadas 6 e 7, foi possível analisar a influência dos diferentes valores de patrimônio na escolha dos times. Dentro de cada rodada, foi realizado o cálculo da média de pontuação para todos esquemas táticos dentro de um limite de patrimônio.

Para a rodada 6, foram obtidos os seguintes resultados como pode ser observado na Figura 68.

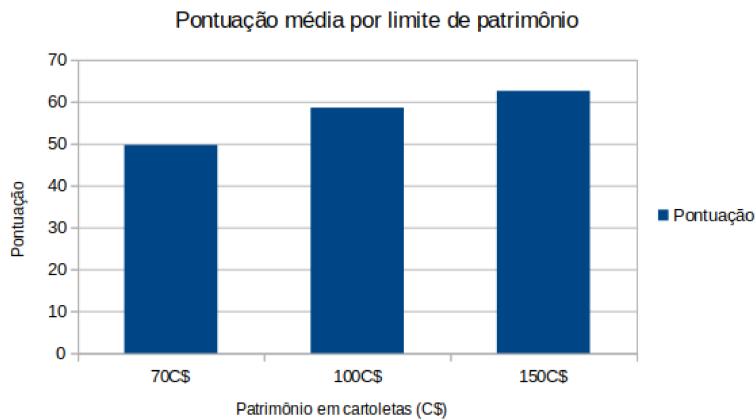


Figura 68 – Pontuação média por esquema tático

Para o limite de patrimônio de 70C\$, foi obtida uma pontuação média de 49.69, enquanto para o limite de 100C\$, foi obtida uma pontuação média de 58.60. Além disso, para 150C\$, a pontuação média foi de 62.61.

Para a rodada 7, foram obtidos os seguintes resultados como pode ser observado na Figura 69.

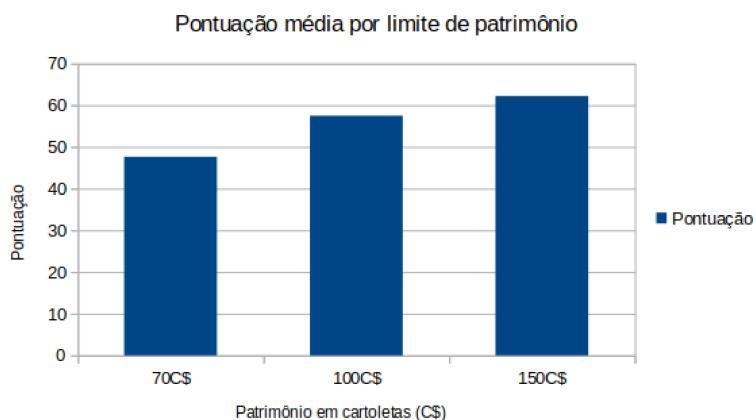


Figura 69 – Pontuação média por esquema tático

Para o limite de patrimônio de 70C\$, foi obtida uma pontuação média de 47.63, enquanto para o limite de 100C\$, foi obtida uma pontuação média de 57.47. Além disso, para 150C\$, a pontuação média foi de 62.20.

## 5 Conclusão

Os resultados obtidos no trabalho sugerem que o limite de patrimônio disponível para escalação influencia na qualidade dos times escalados, pois à medida que ele aumenta, melhores times são escalados em virtude da maior disponibilidade de recursos, possibilitando dessa forma a escolha de jogadores melhores que possuem um maior preço.

Um outro resultado positivo observado no desenvolvimento do trabalho foi o desempenho do algoritmo genético responsável pela escalação dos times. Na grande maioria dos testes realizados, à medida que as gerações se passavam, ele conseguia evoluir os times escalados para times com melhores valores de avaliação.

Uma das contribuições do trabalho foi a formulação matemática do processo de escalação de atletas como um problema de otimização, mantendo dessa forma o desacoplamento entre a modelagem do problema, e o método escolhido para resolução, que nesse trabalho foi um algoritmo genético.

Além disso, a implementação da restrição do limite de patrimônio disponível para escalação dos atletas, além do processo de escolha do melhor time, foi utilizada por meio da construção de um algoritmo genético. Uma outra contribuição observada no desenvolvimento desse trabalho foi a utilização de redes neurais para agrupamento dos jogadores, uma forma alternativa apresentada ao *K-Means* que foi utilizado em um trabalho relacionado.

No desenvolvimento de trabalhos futuros, pode ser realizada a normalização das estatísticas dos jogadores, além de serem criadas redes neurais específicas para cada posição. Além disso, podem ser incorporadas novas variáveis dentro do modelo como o processo de análise de partidas a cada rodada, por meio do histórico de desempenho dos times, para dar preferência à escolha de determinados atletas que naquela ocasião tenham uma maior probabilidade de obter uma pontuação maior. Além disso, podem ser testados diferentes métodos nos operadores genéticos desde o processo de seleção dos pais até o processo de escolha da nova população. Para a seleção dos pais, podem ser realizados testes comparando a utilização do método da roleta, com o torneio e o truncamento. Para o processo de reprodução, podem ser realizados testes comparando a utilização do método do *crossover* simples com o *crossover* múltiplo. Já para o processo de definição da nova população, podem ser realizados testes comparando a utilização do método da reinserção pura com o elitismo, e a reinserção uniforme.

Portanto, acredita-se que a modelagem desenvolvida nesse trabalho pode ser utilizada não apenas para o CartolaFC, mas também para *fantasy games* existentes de outras modalidades esportivas como por exemplo o *FanDuel* e *DraftKings* ou ainda futuros jogos,

onde se deseja encontrar um conjunto de atletas no qual existam restrições como preço e esquema tático.

# Referências

- CARVALHO, A. P. de Leon F. de. *Redes neurais artificiais*. 2019. Disponível em: <<http://conteudo.icmc.usp.br/pessoas/andre/research/neural/>>. Acesso em: 22 fev. 2019. Citado na página 12.
- DUNNINGTON, N. *Fantasy Football Projection Analysis*. 2015. Disponível em: <<https://pdfs.semanticscholar.org/8616/917f4adcf9448c107861aa217c66576fb2c8.pdf>>. Acesso em: 05 fev. 2019. Citado na página 21.
- FARIA, B. *Boxplot - Como interpretar?* 2018. Disponível em: <<http://www.abgconsultoria.com.br/blog/boxplot-como-interpretar/>>. Acesso em: 18 fev. 2019. Citado 2 vezes nas páginas 16 e 17.
- GLOBO. *Entenda mais como funciona*. 2018. Disponível em: <<https://cartolafc.globo.com/#!/entenda-mais#como-funciona>>. Acesso em: 15 fev. 2019. Citado na página 18.
- GLOBO. *Cartola PRO 2019 sorteia carro 0km no fim do ano e aumenta número de ligas; veja os benefícios*. 2019. Disponível em: <<https://globoesporte.globo.com/cartola-fc/pro/noticia/cartola-pro-2019-sorteia-carro-0km-no-fim-do-ano-e-aumenta-numero-de-ligas-veja-os-beneficios.ghtml>>. Acesso em: 08 abr. 2019. Citado na página 5.
- GOLDBERG, D. E. *Genetic Algorithms in Search, Optimization and Machine Learning*. [S.l.]: Addison-Wesley Longman Publishing Co., Inc., 1989. Citado na página 13.
- GOMIDE, H. *cartola*. 2019. Disponível em: <<https://github.com/henriquepgomide/caRtola>>. Acesso em: 11 mar. 2019. Citado na página 23.
- GRANATYR, J. *Algoritmos Genéticos em Python*. 2019. Disponível em: <<https://www.udemy.com/algoritmos-geneticos-em-python/learn/lecture/9664490#questions>>. Acesso em: 18 mar. 2019. Citado na página 33.
- GRANATYR, J. *Jones Granatyr - Professor*. 2019. Disponível em: <<https://www.udemy.com/user/jones-granatyr/>>. Acesso em: 10 mar. 2019. Citado na página 33.
- HERMANN, E.; NTOSO, A. *Machine Learning Applications in Fantasy Basketball*. 2015. Disponível em: <<https://pdfs.semanticscholar.org/8616/917f4adcf9448c107861aa217c66576fb2c8.pdf>>. Acesso em: 03 fev. 2019. Citado na página 20.
- HOLLAND, J. H. *Adaptation in Natural and Artificial Systems*. [S.l.]: University of Michigan Press, 1975. Citado na página 13.
- JULIA, R. M. da S. *Computação evolutiva - Conceitos complementares*. 2018. Acesso em: 19 fev. 2019. Citado 3 vezes nas páginas 13, 15 e 16.
- JULIA, R. M. da S. *Redes neurais - Regra Delta Generalizada*. 2018. Acesso em: 20 fev. 2019. Citado na página 12.

- JULIA, R. M. da S. *Sistemas Conexionistas - Introdução às Redes Neurais*. 2018. Acesso em: 19 fev. 2019. Citado na página 9.
- KERAS. *Keras Documentation*. 2019. Disponível em: <<https://keras.io/>>. Acesso em: 30 mar. 2019. Citado na página 30.
- KIEFFER, P. *Multiclass Iris prediction with tensorflow keras*. 2018. Disponível em: <<https://www.kaggle.com/pierrek20/multiclass-iris-prediction-with-tensorflow-keras>>. Acesso em: 07 mar. 2019. Citado na página 29.
- LIMA, H. A.; PASQUINI, D. de P.; TRAVIZAN, A. N. *Ciência de dados aplicada na predição de escalação de equipes para o jogo Cartola FC*. 2018. Citado 2 vezes nas páginas 4 e 21.
- MCCULLOCH, W. S.; PITTS, W. *A logical calculus of the ideas immanent in nervous activity*. 1943. Disponível em: <<https://link.springer.com/article/10.1007/BF02478259>>. Acesso em: 20 mar. 2019. Citado na página 9.
- MONARD, M. C.; BARANAUSKAS, J. A. *Conceitos sobre Aprendizado de Máquina*. 2003. Disponível em: <<http://dcm.ffclrp.usp.br/~augusto/publications/2003-sistemas-inteligentes-cap4.pdf>>. Acesso em: 01 fev. 2019. Citado na página 4.
- OLIVEIRA, G. M. B. *Conceitos Complementares de Algoritmos Genéticos*. 2018. Acesso em: 27 mar. 2019. Citado 3 vezes nas páginas 14, 15 e 16.
- PUCRIO. *Métodos de Otimização*. 2019. Disponível em: <[https://www.maxwell.vrac.puc-rio.br/7603/7603\\\_\\\_4.PDF](https://www.maxwell.vrac.puc-rio.br/7603/7603\_\_4.PDF)>. Acesso em: 04 mar. 2019. Citado na página 13.
- RACHKA, S. *Why is the ReLU function not differentiable at x=0?* 2018. Disponível em: <<https://sebastianraschka.com/faq/docs/relu-derivative.html>>. Acesso em: 10 mar. 2019. Citado na página 10.
- REZENDE, S. O. *Mineração de dados. Sistemas inteligentes: fundamentos e aplicações*. [S.l.]: Editora Manole, 2003. Citado na página 4.
- ROSA, J. L. G. *Redes Neurais*. 2019. Disponível em: <<http://wiki.icmc.usp.br/images/e/ec/RP1RNAa.pdf>>. Acesso em: 25 mar. 2019. Citado na página 12.
- ROSENBLATT, F. *The perceptron: A probabilistic model for information storage and organization in the brain*. 1958. Disponível em: <<https://psycnet.apa.org/record/1959-09865-001>>. Acesso em: 20 mar. 2019. Citado na página 11.
- SILVA, J. M. M. da. *Introdução às Redes Neurais Artificiais Perceptrons de Múltiplas Camadas II*. 2019. Disponível em: <<http://www.professores.uff.br/jmarcos/wp-content/uploads/sites/112/2017/08/aula4.pdf>>. Acesso em: 23 mar. 2019. Citado na página 12.
- STERBAK, T. *Guide To Multi-Class Multi-Label Classification With Neural Networks In Python*. 2017. Disponível em: <<https://www.depends-on-the-definition.com/guide-to-multi-label-classification-with-neural-networks/>>. Acesso em: 25 fev. 2019. Citado na página 11.
- TAFNER, M. A. *Redes Neurais Artificiais: Aprendizado e Plasticidade*. 1998. Disponível em: <[http://www.cerebromente.org.br/n05/tecnologia/rna\\_i.htm](http://www.cerebromente.org.br/n05/tecnologia/rna_i.htm)>. Acesso em: 01 mar. 2019. Citado 2 vezes nas páginas 10 e 11.

VISCONDI, G. de F.; GARCIA, N. M.; JUSTO, D. *Aplicação de aprendizado de máquina para otimização da escaladação de time no jogo Cartola FC*. 2017. Disponível em: <[https://www.researchgate.net/publication/321899230\\_Aplicacao\\_de\\_aprendizado\\_de\\_maquina\\_para\\_otimizacao\\_da\\_escalacao\\_de\\_time\\_no\\_jogo\\_Cartola\\_FC](https://www.researchgate.net/publication/321899230_Aplicacao_de_aprendizado_de_maquina_para_otimizacao_da_escalacao_de_time_no_jogo_Cartola_FC)>. Acesso em: 10 fev. 2019. Citado 2 vezes nas páginas 4 e 21.